

データ駆動科学シンポジウム
「ベイズ計測の最前線」
ベイズ計測の基礎から展開へ

東京大学・大学院新領域創成科学研究科
複雑理工学専攻

岡田真人

本基調講演のスライドは岡田研HPにて公開

<https://mns.k.u-tokyo.ac.jp/lab.html#overview>

自己紹介

- 大阪市立大学理学部物理学科 (1981 - 1985)
 - アモルファスシリコンの成長と構造解析
- 大阪大学大学院理学研究科(金森研) (1985 – 1987)
 - 希土類元素の光励起スペクトルの理論
- 三菱電機 (1987 - 1989)
 - 化合物半導体(半導体レーザー)の結晶成長
- 大阪大学大学院基礎工学研究科生物工学(福島研) (1989 - 1996)
 - 置み込み深層ニューラルネット
 - 情報統計力学(ベイズ推論と統計力学の数理的等価性)
- JST ERATO 川人学習動態脳プロジェクト (1996 - 2001)
 - 計算論的神経科学
- 理化学研究所 脳科学総合研究センタ 甘利T(2001 - 04/06)
 - ベイズ推論, 機械学習, データ駆動型科学
- 東京大学・大学院新領域創成科学研究所 複雑理工学専攻 (2004/07 –)
 - 情報統計力学、データ駆動科学

自己紹介のまとめ

- ・大学と大学院修士課程で(物性)物理学の教育研究
- ・(株)三菱電機で半導体レーザーの量産スタッフ
- ・大学院博士課程、助手、ERATO研究員でニューラルネット/情報統計力学/計算論的神経科学の研究
- ・東大新領域複雑理工で、脳科学、化学、地球科学など**多様な自然科学**と出会い、それらを普遍的取り扱うデータ駆動科学を創設。

本セミナーの目的の内容

- ・ベイズ計測：計測科学に必要な最小限としてのベイズ推論の紹介
 - ・ベイズ計測三種の神器
- ・ベイズ計測の基礎の紹介
 - ・直線回帰 $y=ax+b$ のベイズ計測
- ・ベイズ計測の展開へ
 - ・ベイズ計測の普及の戦略は何か？
 - ・ベイズ計測の習得方法
 - ・ベイズ計測の多様な計測への展開
 - ・SPring-8全ビームラインベイズ化計画

内容

- ・自己紹介
- ・階層的自然観とデータ駆動科学：ベイズ推論とスペースモデリングによる自然記述の普遍的枠組み
- ・ベイズ計測の導入
 - ・計測科学の必須条件
 - ・ベイズ計測三種の神器
 - ・ $y=ax+b$ のベイズ計測の解析的取り扱い
- ・非線形系にするベイズ計測
 - ・スペクトル分解
 - ・メスバウア一分光
 - ・小角散乱
- ・ベイズ計測の啓蒙と普及の戦略
- ・まとめと今後の展開

内容

- ・自己紹介
- ・階層的自然観とデータ駆動科学：ベイズ推論とスペースモデリングによる自然記述の普遍的枠組み
- ・ベイズ計測の導入
 - ・計測科学の必須条件
 - ・ベイズ計測三種の神器
 - ・ $y=ax+b$ のベイズ計測の解析的取り扱い
- ・非線形系にするベイズ計測
 - ・スペクトル分解
 - ・メスバウア一分光
 - ・小角散乱
- ・ベイズ計測の啓蒙と普及の戦略
- ・まとめと今後の展開

要素還元主義と階層的自然観

- 要素還元主義
 - 物理学の法則の獲得をよりミクロな方向に進め、得られた基礎方程式からの演繹で、世界を理解する立場
- 階層的自然観
 - 自然を各階層に分離して、階層ごとに研究することで、世界を理解する立場
 - 以下の状況から、階層的自然観が正しいと言わざるを得ない
 - 第一原理計算の実情
 - 愛情などの高度な認知機能の解明

階層的自然観と実験データ解析

- ・階層的自然観の立場では、各階層の数理モデルの構築のためは、ミクロレベルからの演繹を諦めたために、その帰結として、実験データを用いる必要がある。
- ・実験データの解析には、その現象を説明するす**数理モデルがないかあるか**で、二つの戦略が必要である
- ・実験データを解析する**データ駆動科学**の数理情報学的枠組みは、その二つに対応して、**スペースモデリング(SpM)**と**ベイズ推論**の二つが用意されている

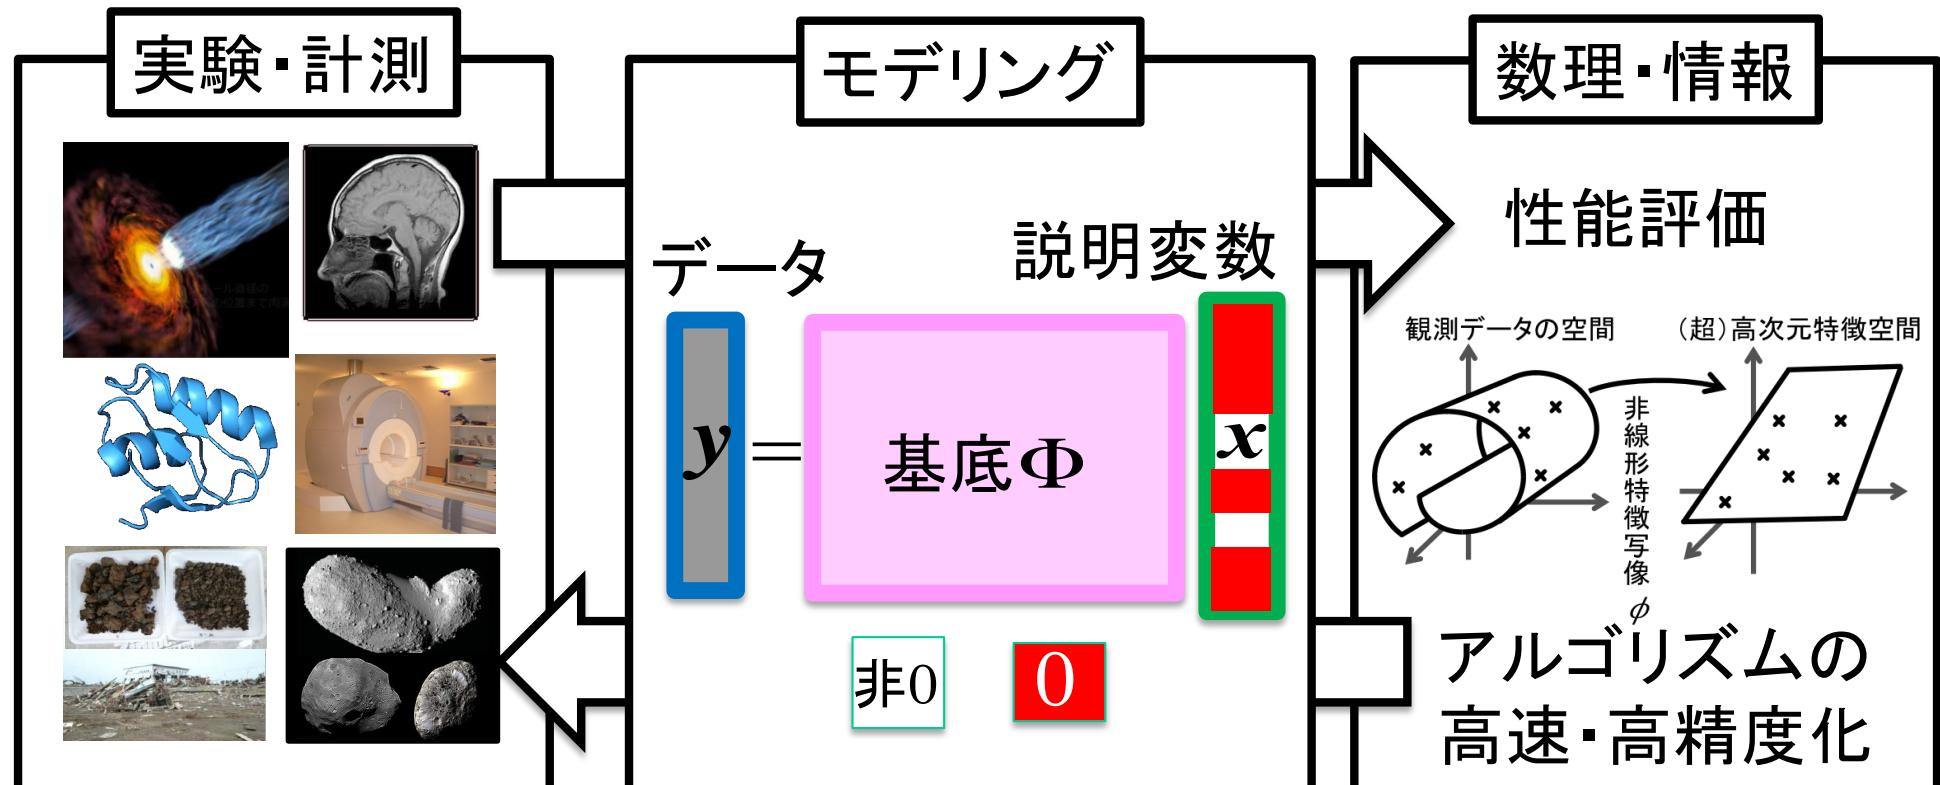
物理学とスペースモデリング(SpM)

- ・古典力学や量子力学の前段階で、スペースモデリング(SpM)は活用されている歴史
- ・ニュートン力学に対するKeplerの法則
 - ・公転周期 T と公転半径 R
- ・前期量子論
 - ・プランクの輻射の理論、アインシュタインの光量子仮説
- ・これらは全て、そのレベルを記述する数理モデルがない段階で、実験データから特徴量をヒトが決め、その特徴量を用いて、現象を定量的に記述する現象論である

新学術領域研究 平成25～29年度 スペースモデリングの深化と高次元データ駆動科学の創成

領域代表岡田の個人的な狙い

世界を系統的に記述したい
その方法論と枠組みを創りたい
ヒトが世界を認識するとは?



階層的自然観での普遍的な構造 ベイズ計測の必然性

現在考察している階層

切斷!!

ミクロな階層

- 数理モデルのフリーパラメータの決定精度が、そのモデルの正しさ証明つながる
- ミクロなレベルと分断されているため、一般に複数の数理モデルが存在する

ベイズ計測の必然性(パラメータ推定、モデル選択)

内容

- ・自己紹介
- ・階層的自然観とデータ駆動科学: ベイズ推論とスパースモデリングによる自然記述の普遍的枠組み
- ・ベイズ計測の導入
 - ・計測科学の必須条件
 - ・ベイズ計測三種の神器
 - ・ベイズ計測の習得法
 - ・ $y=ax+b$ のベイズ計測の解析的取り扱い
- ・非線形系にするベイズ計測
 - ・スペクトル分解
 - ・メスバウア一分光
 - ・小角散乱
- ・ベイズ計測の啓蒙と普及の戦略
- ・まとめと今後の展開

計測科学の必須条件

- 数理モデルのフリー・パラメータを決める
系統的枠組み
- 複数モデルをデータだけから選択する
系統的枠組み
- 同一物質に対する複数の計測データを
統合する系統的枠組み

ベイズ計測三種の神器

- パラメータの事後確率推定: 数理モデルのフリーパラメータを決める系統的枠組み
- ベイズ的モデル選択: 複数モデルをデータだけから選択する系統的枠組み
- ベイズ統合: 同一物質に対する複数の計測データを統合する系統的枠組み
 - ベイズ統合の説明は水牧先生@熊大の招待講演

ベイズ計測の習得法

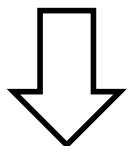
1. $y=ax+b$ への解析的計算の適用
2. $y=ax+b$ への数値計算の適用
3. 1.と2.の結果が一致するのを確認
4. ベイズ的スペクトル分解
5. 各課題に取り組む

ベイズ計測とは？

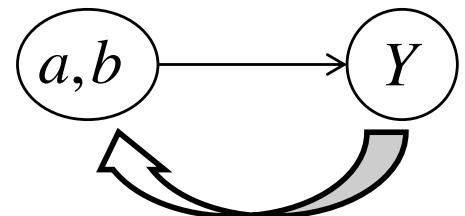
ベイズ推論

$$p(Y, a, b) = p(Y | a, b)p(a, b) = p(a, b | Y)p(Y)$$

<ベイズの定理>



生成(因果律)



$$p(a, b | Y) = \frac{p(Y | a, b)p(a, b)}{p(Y)} \propto \exp(-nE(a, b))p(a, b)$$

$p(a, b | Y)$: 事後確率。データが与えられたもとでの物理パラメータの確率。

$p(a, b)$: 事前確率。あらかじめ設定しておく必要がある。これまで蓄積されてきた科学的知見

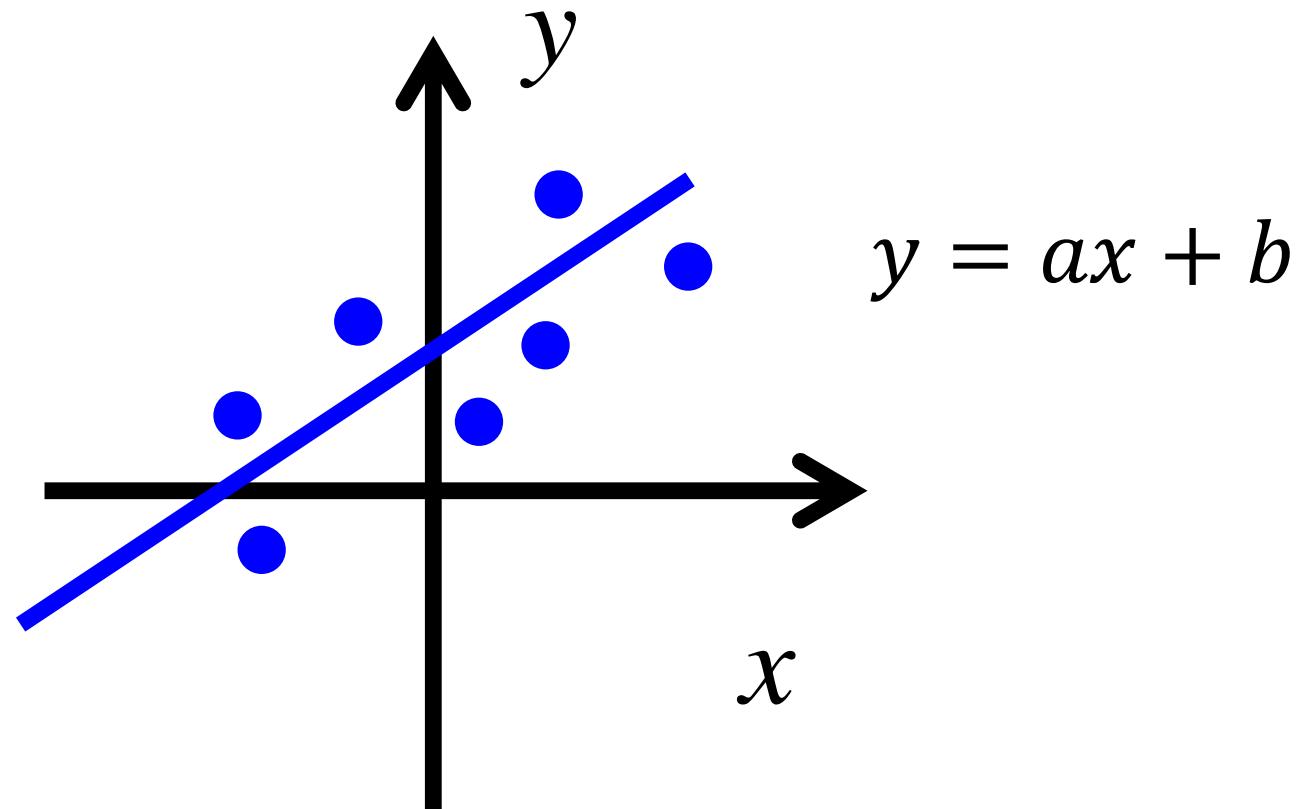
ベイズ計測三種の神器

1. 物理パラメータの事後確率分布定
2. モデル選択
3. データ統合

ベイズ計測の利点

$y=ax+b$ の取り扱いを通じて

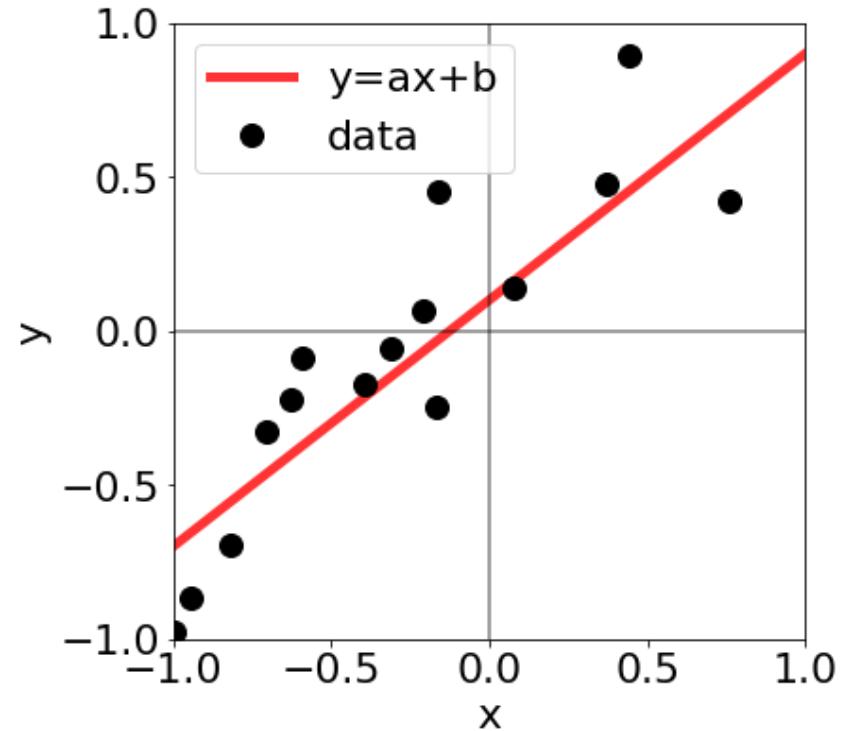
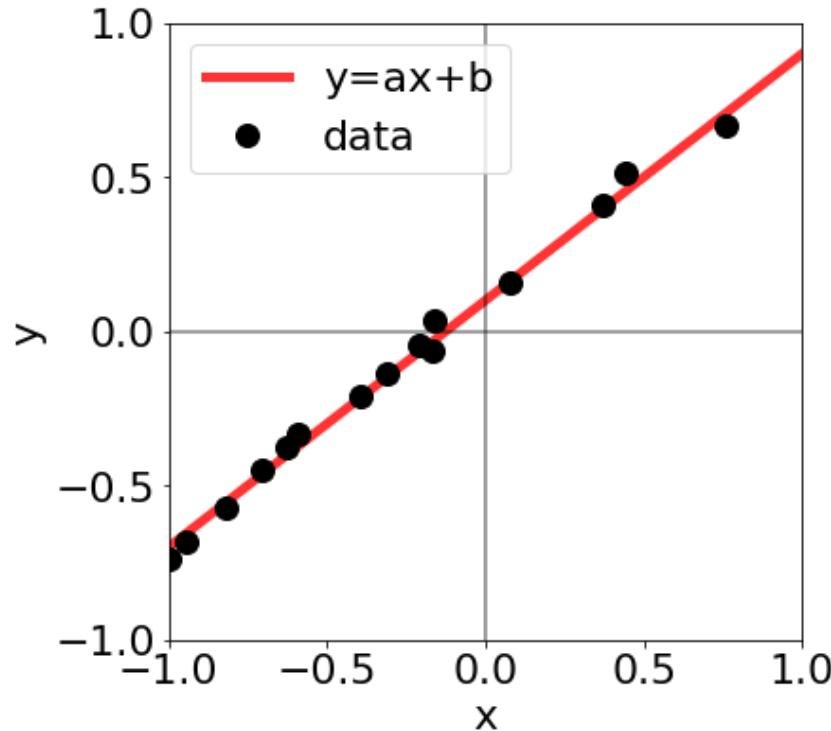
現状でも用いられている最も簡単な例



傾き a : 系の線形応答、バネ定数、電気伝導度、誘電率

ベイズ計測の利点

$y=ax+b$ の取り扱いを通じて



この二つの推定精度の違いを数学的に表現したい
準備として従来手法の最小二乗法

$y=ax+b$ の最小二乗法

$$E(a, b) = \frac{1}{N} \sum_{i=1}^N (y_i - (ax_i + b))^2$$

二乗誤差 $E(a, b)$ を最小にするようにパラメータをフィット(最小二乗法)

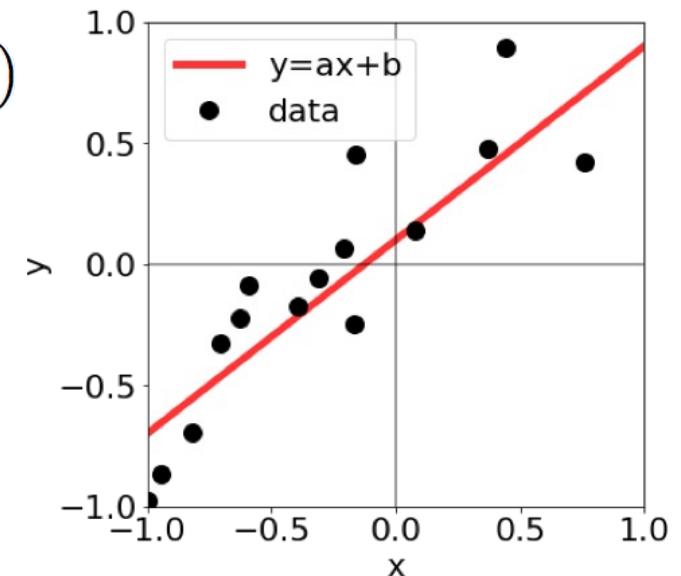
$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i = 0 \text{ とする場合}$$

$$E(a, b) = \frac{1}{2} \left(\bar{x}^2 \left(a - \frac{\bar{xy}}{\bar{x}^2} \right)^2 + (b - \bar{y})^2 - \frac{\bar{xy}^2}{\bar{x}^2} - \bar{y}^2 + \bar{y}^2 \right) \quad a_0 = \frac{\bar{xy}}{\bar{x}^2} \quad b_0 = \bar{y}$$

$$= \mathcal{E}_a(a) + \mathcal{E}_b(b) + E(a_0, b_0) \geq E(a_0, b_0)$$

平均: $\bar{y} = \frac{1}{N} \sum_{i=1}^N y_i$, 分散: $\bar{x}^2 = \frac{1}{N} \sum_{i=1}^N x_i^2$

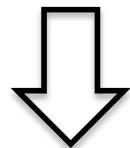
$$\bar{xy} = \frac{1}{N} \sum_{i=1}^N x_i y_i$$



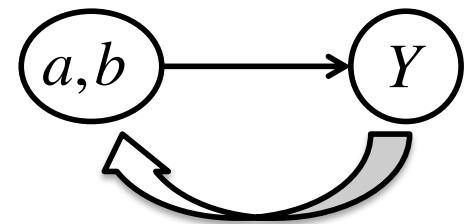
ベイズの定理による 神器1: パラメータの事後確率推定 (1/4)

$$p(Y, a, b) = p(Y | a, b)p(a, b) = p(a, b | Y)p(Y)$$

<ベイズの定理>



生成(因果律)



$$p(a, b | Y) = \frac{p(Y | a, b)p(a, b)}{p(Y)} \propto \exp(-nE(a, b))p(a, b)$$

$p(a, b | Y)$: 事後確率。データが与えられたもとでの、パラメータの確率。

$p(a, b)$: 事前確率。あらかじめ設定しておく必要がある。
これまで蓄積してきた科学的知見

神器1: パラメータの事後確率推定 (2/4)

$$y_i = ax_i + b + n_i$$

$$p(n_i) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{n_i^2}{2\sigma^2}\right)$$

$$p(n_i) = p(y_i|a, b) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - (ax_i + b))^2}{2\sigma^2}\right)$$

$$\begin{aligned} p(Y|a, b) &= \prod_{i=1}^N p(y_i|a, b) \\ &= \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^N \exp\left(-\frac{\sum_{i=1}^N (y_i - (ax_i + b))^2}{2\sigma^2}\right) \\ &= \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^N \exp\left(-\frac{N}{\sigma^2} E(a, b)\right) \end{aligned}$$

岡田と片上の講演の定式化の違い

$$y_i = ax_i + b + n_i \quad p(n_i) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{n_i^2}{2\sigma^2}\right)$$

岡田（基調講演）: n_i を固定して計算

こちらの方が簡単

片上(招待講演2): n_i の揺らぎを考慮して計算

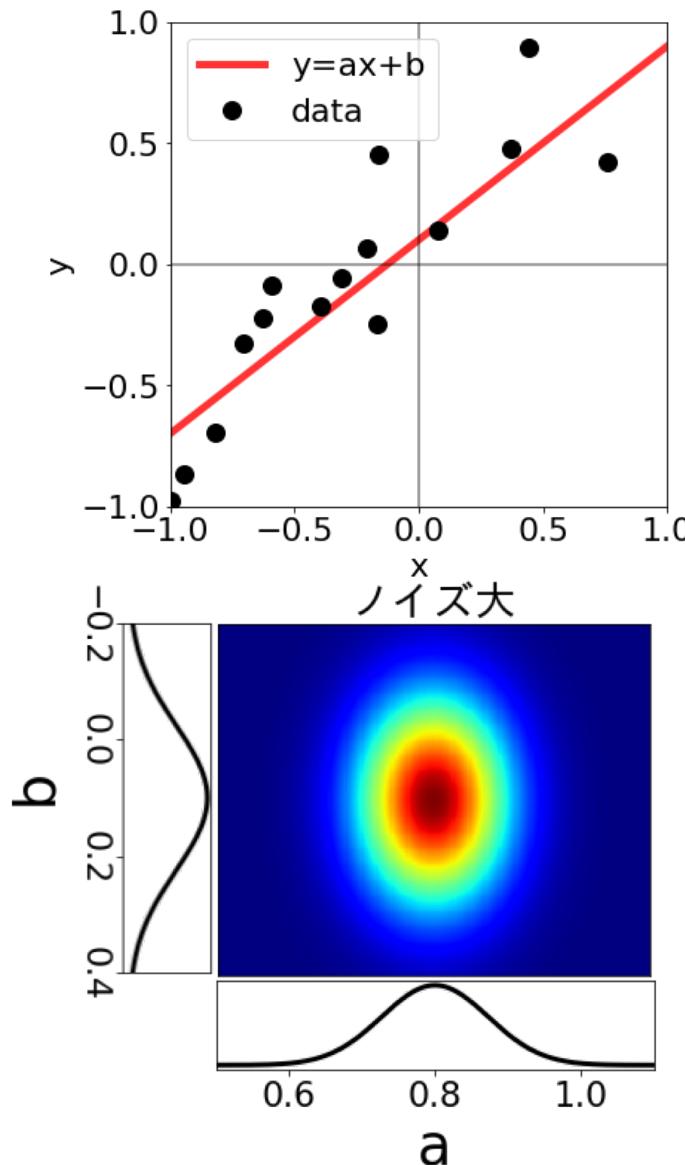
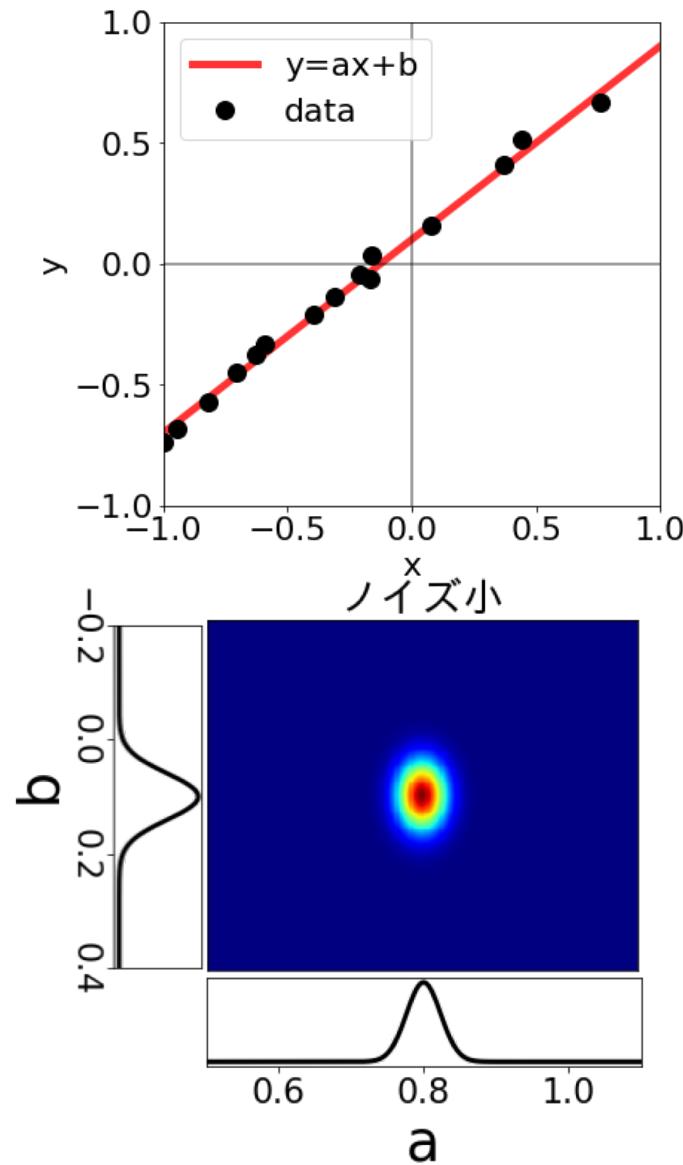
n_i の揺らぎが自由エネルギーの差に影響

こちらの方がすごく難しい

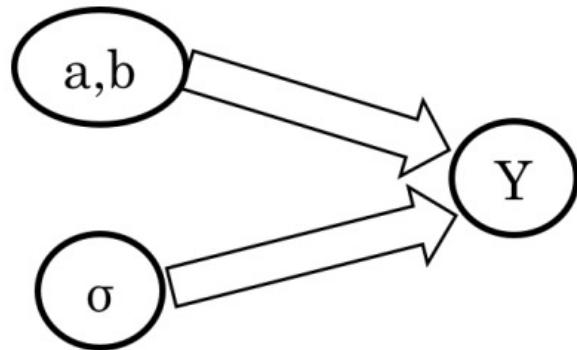
神器1: パラメータの事後確率推定 (3/4)

$$\begin{aligned} p(a, b|Y) &= \frac{p(Y|a, b)p(a, b)}{p(Y)} \propto p(Y|a, b) \\ &= \exp \left\{ -\frac{N}{\sigma^2} \left(\mathcal{E}_a(a) + \mathcal{E}_b(b) + E(a_0, b_0) \right) \right\} \\ &\propto \exp \left\{ -\frac{N}{\sigma^2} \left(\mathcal{E}_a(a) + \mathcal{E}_b(b) \right) \right\} \\ &= \exp \left\{ -\frac{N\bar{x}^2}{2\sigma^2} (a - a_0)^2 + \frac{N}{2\sigma^2} (b - b_0)^2 \right\} \end{aligned}$$

神器1: パラメータの事後確率推定 (4/4)



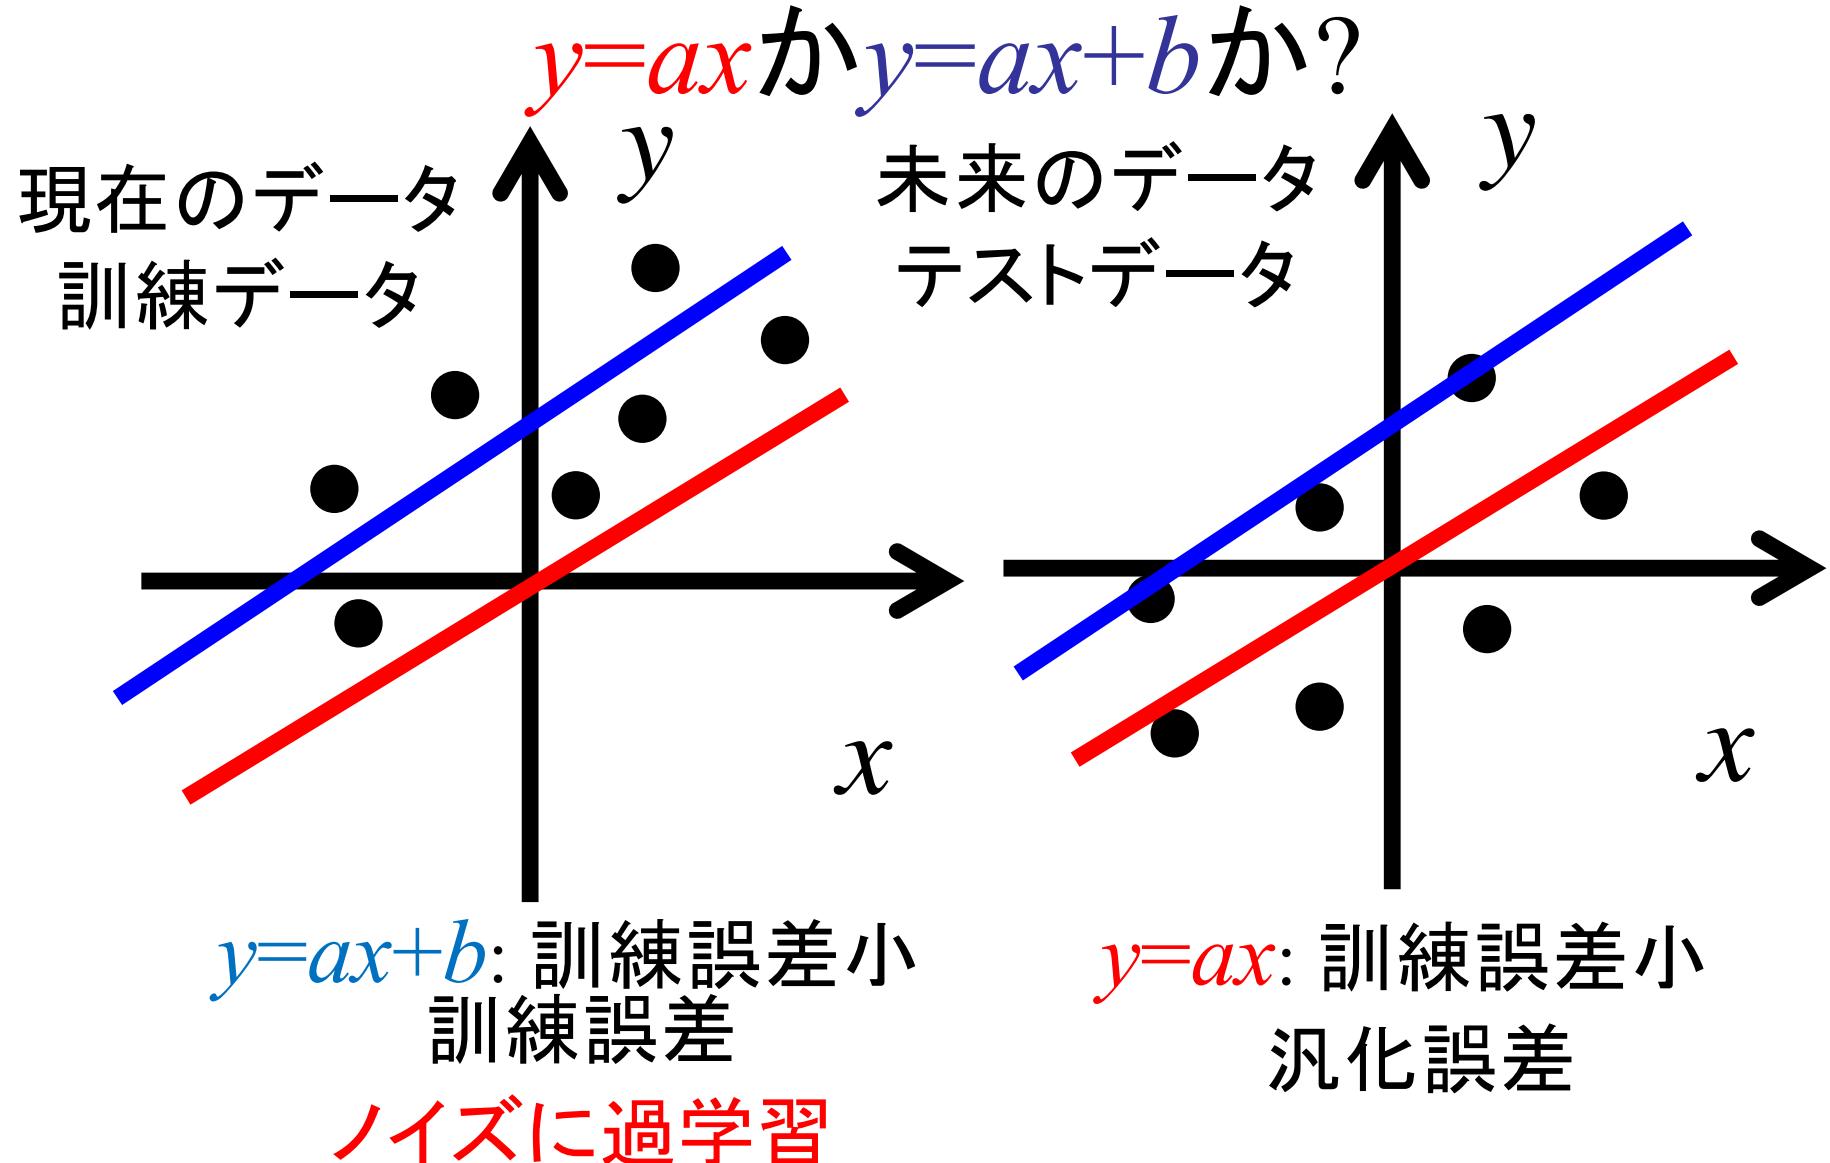
神器1: パラメータの事後確率推定 ノイズ分散推定



$$\begin{aligned}
 p(\sigma^2 | Y) &\propto \int da db p(Y|a, b, \sigma^2) \\
 &= \left(\frac{1}{\sqrt{2\pi}\sigma^2} \right)^N \int da db \exp \left\{ -\frac{N}{\sigma^2} E(a, b) \right\} \\
 &= \left(\frac{1}{\sqrt{2\pi}\sigma^2} \right)^N \left\{ \exp \left(-\frac{N}{\sigma^2} E(a_0, b_0) \right) + \int da \exp \left(-\frac{N\bar{x}^2}{2\sigma^2} (a - a_0)^2 \right) + \int db \exp \left(-\frac{N}{2\sigma^2} (b - b_0)^2 \right) \right\} \\
 &= (2\pi\sigma^2)^{-\frac{N-2}{2}} (N^2 \bar{x}^2)^{\frac{1}{2}} \exp \left(-\frac{N}{\sigma^2} E(a_0, b_0) \right)
 \end{aligned} \tag{25}$$

$$\sigma^2 = \frac{NE(a_0, b_0)}{N-2} = \frac{1}{N-2} \sum_{i=1}^N \{y_i - (a_0 x_i + b_0)\}^2$$

問題意識 神器2: ベイズ的モデル選択



モデル選択できる理由: 汎化誤差は観測ノイズに依存する

神器2: ベイズ的モデル選択

1. 欲しいのは $p(K|Y)$

2. θ がないぞ

3. $p(K, \theta, Y)$ の存在を仮定

$$p(K, \theta, Y) = p(Y|\theta, K)p(K)$$

$$p(Y|\theta, K) = \prod_{i=1}^n p(y_i|\theta) \propto \exp(-nE(\theta))$$

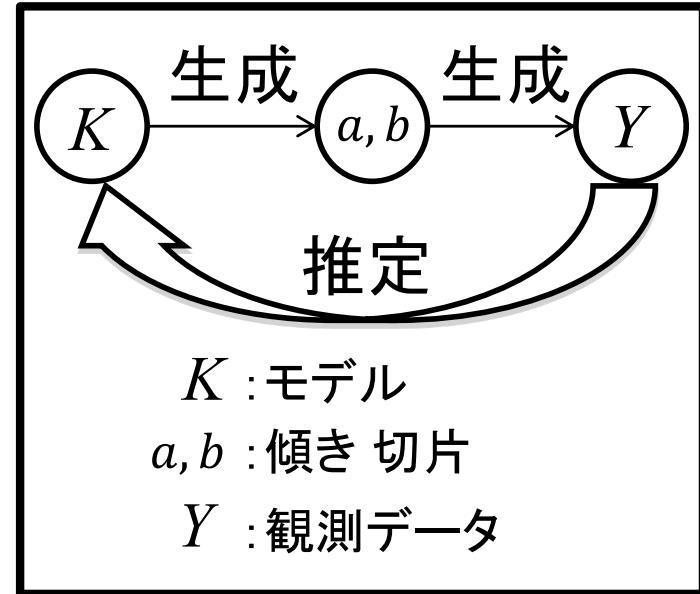
4. 無駄な自由度の系統的消去: 周辺化, 分配関数

$$p(K, Y) = \int p(K, \theta, Y) d\theta$$

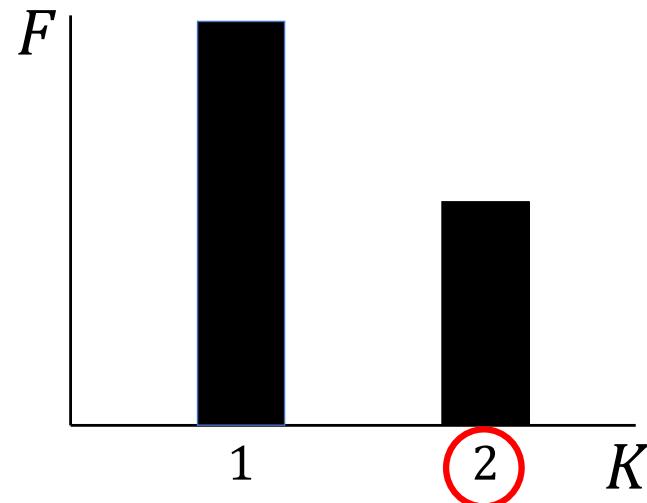
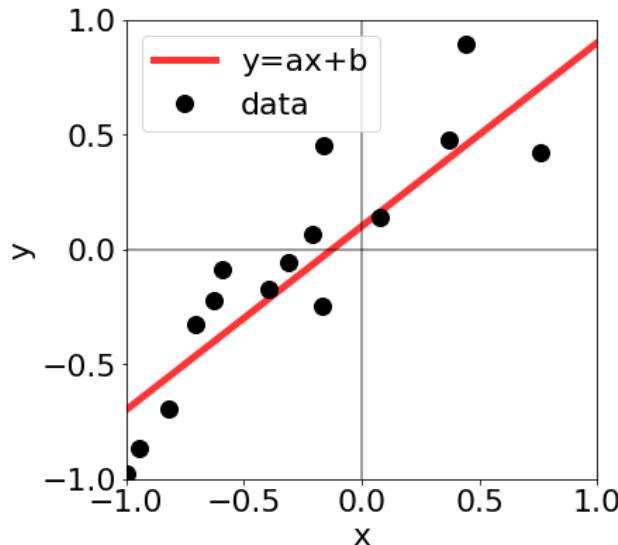
$$p(K|Y) = \frac{p(Y|K)p(K)}{p(Y)} \propto p(K) \int \exp(-nE(\theta)) p(\theta) d\theta$$

$$F(K) = -\log \int \exp(-nE(\theta)) p(\theta) d\theta$$

自由エネルギーを最小にするモデル K を求める.



モデル選択: 自由エネルギー差



- $K = 1 : y = ax$
- $K = 2 : y = ax + b$

$$F(K=1) = N \left\{ \frac{1}{\sigma^2} E(a_0) + \frac{\log N}{2N} \right\}$$

$$F(K=2) = N \left\{ \frac{1}{\sigma^2} E(a_0, b_0) + \frac{\log N}{N} \right\}$$

データのみからモデルを選択できる

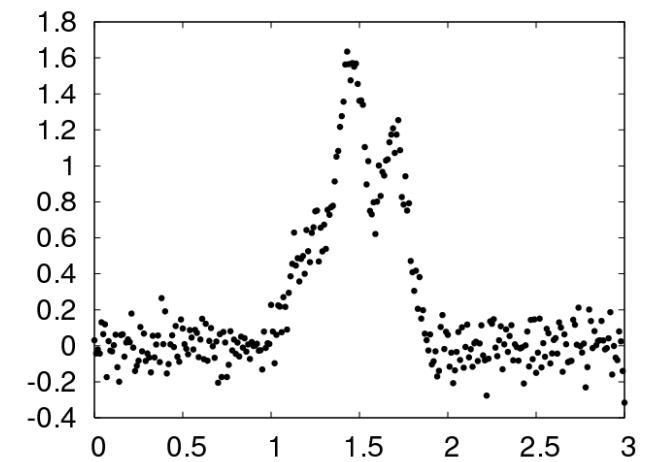
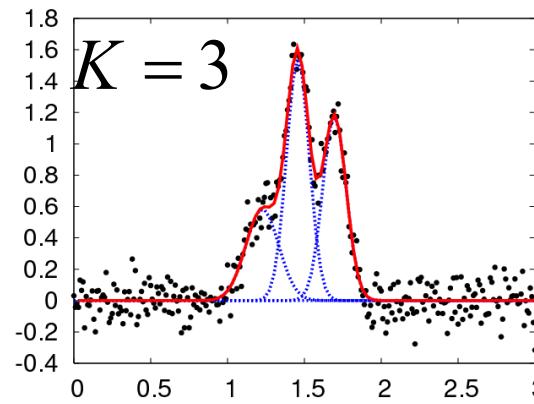
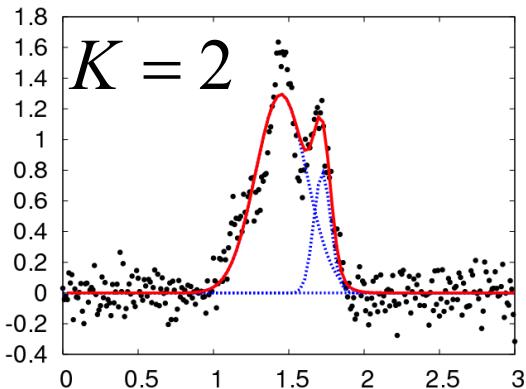
まとめ: ベイズ計測三種の神器 $y=ax+b$ の解析取り扱いを通じて

- 従来の最小二乗法
 - 1. 物理パラメータの点推定
- ベイズ計測
 1. 物理パラメータの確率分布推定
 2. データからのベイズ的モデル選択
 3. ベイズ統合: 今回は説明を省略
- 水牧先生の基調講演

内容

- ・自己紹介
- ・階層的自然観とデータ駆動科学: ベイズ推論とスパースモデリングによる自然記述の普遍的枠組み
- ・ベイズ計測の導入
 - ・計測科学の必須条件
 - ・ベイズ計測三種の神器
 - ・ベイズ計測の習得法
 - ・ $y=ax+b$ のベイズ計測の解析的取り扱い
- ・非線形系にするベイズ計測
 - ・スペクトル分解
 - ・メスバウア一分光
 - ・小角散乱
- ・ベイズ計測の啓蒙と普及の戦略
- ・まとめと今後の展開

ベイズ的スペクトル分解



Nagata, Sugita and Okada, Bayesian spectral deconvolution
with the exchange Monte Carlo method, *Neural Networks* 2012

スペクトル分解の定式化

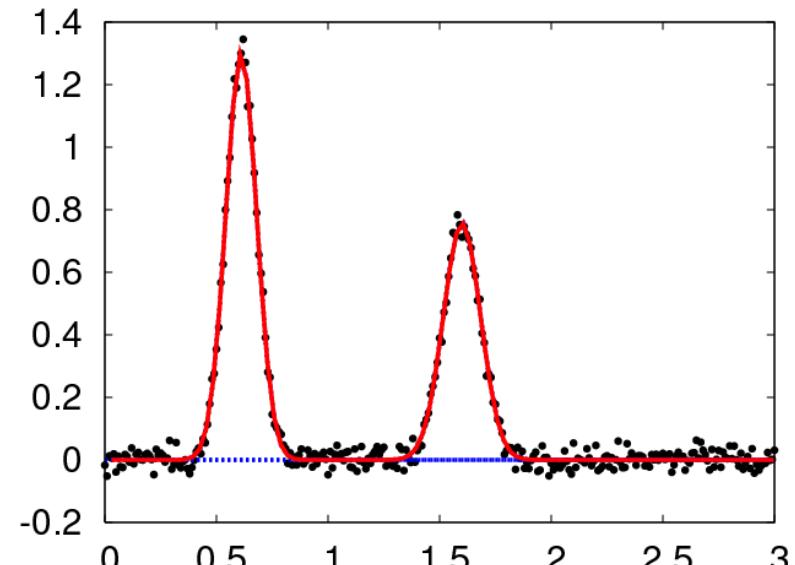
ガウス関数(基底関数)の足し合わせにより、スペクトルデータを近似

観測データ: $D = \{x_i, y_i\}_{i=1}^n$

x_i : 入力 y_i : 出力

$$f(x; \theta) = \sum_{k=1}^K a_k \exp\left(-\frac{b_k(x - \mu_k)^2}{2}\right)$$

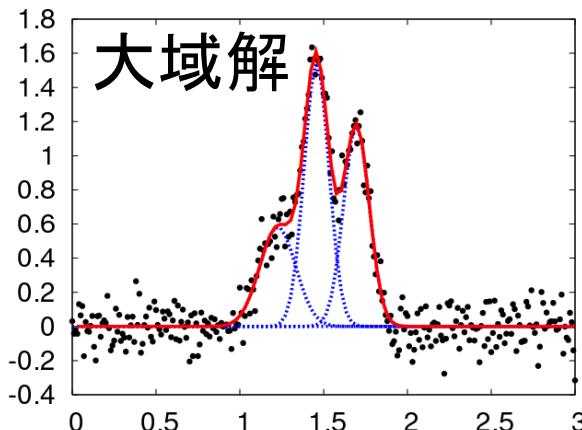
$$\theta = \{a_k, b_k, \mu_k\} \quad k = 1, \dots, K$$



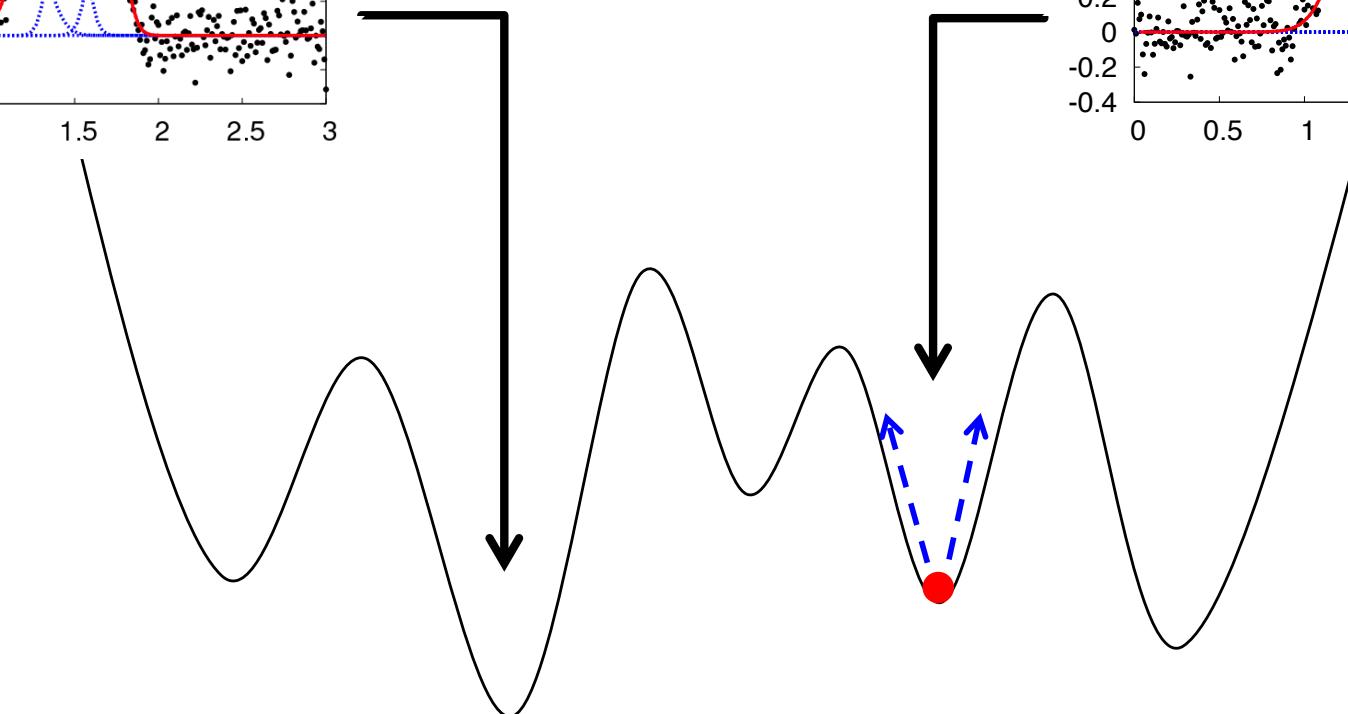
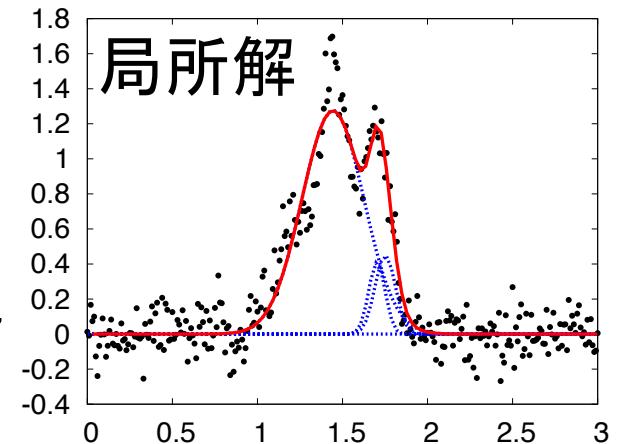
二乗誤差を最小にするようにパラメータをフィット(最小二乗法)

$$E(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i; \theta))^2$$

スペクトル分解従来法: 最急降下法 誤差関数は局所解を持つ



<通常の最適化法>
e.g., 最急降下法



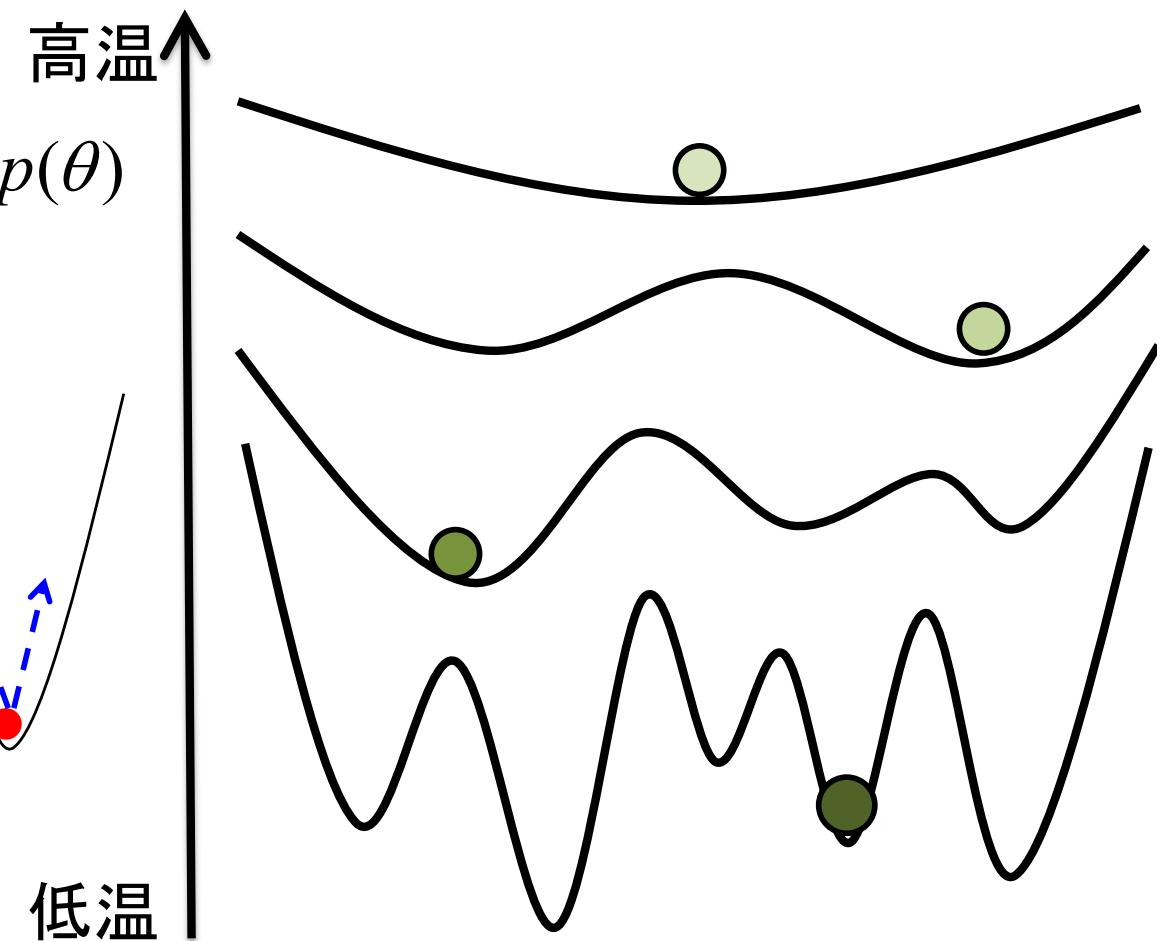
モンテカルロ法の適用 レプリカ交換モンテカルロ法

メトロポリス法

$$p_\beta(\theta) \propto \exp\left(-\frac{n}{\sigma^2} \beta E(\theta)\right) p(\theta)$$



レプリカ交換モンテカルロ法



K. Hukushima, K. Nemoto, *J. Phys. Soc. Jpn.* **65** (1996).

モデル選択: 自由エネルギーの導入

1. 欲しいのは $p(K|Y)$

2. θ がないぞ

3. $p(K, \theta, Y)$ の存在を仮定

$$p(K, \theta, Y) = p(Y|\theta, K)p(K)$$

$$p(Y|\theta, K) = \prod_{i=1}^n p(y_i|\theta) \propto \exp(-nE(\theta))$$

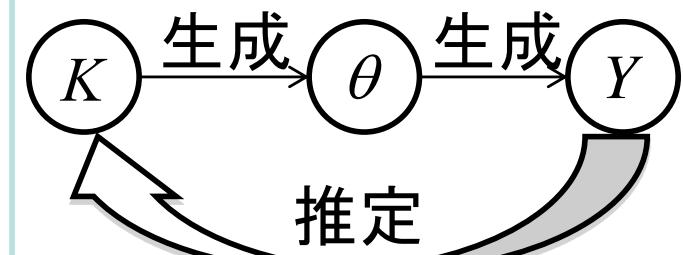
4. 無駄な自由度の系統的消去: 周辺化, 分配関数

$$p(K, Y) = \int p(K, \theta, Y) d\theta$$

$$p(K|Y) = \frac{p(Y|K)p(K)}{p(Y)} \propto p(K) \int \exp(-nE(\theta)) p(\theta) d\theta$$

$$F(K) = -\log \int \exp(-nE(\theta)) p(\theta) d\theta = E - TS$$

自由エネルギーを最小にする個数 K を求める.

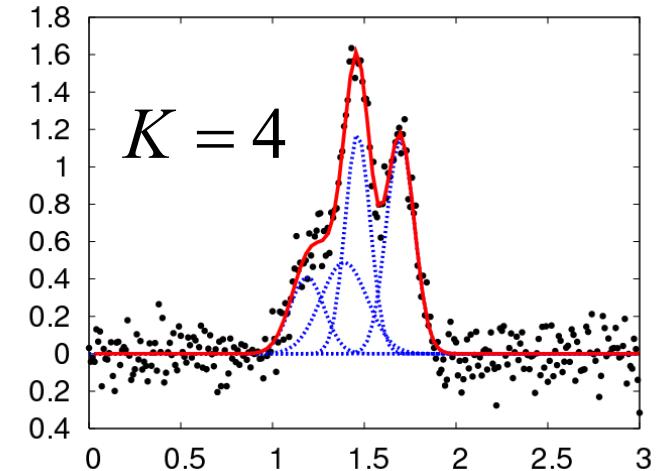
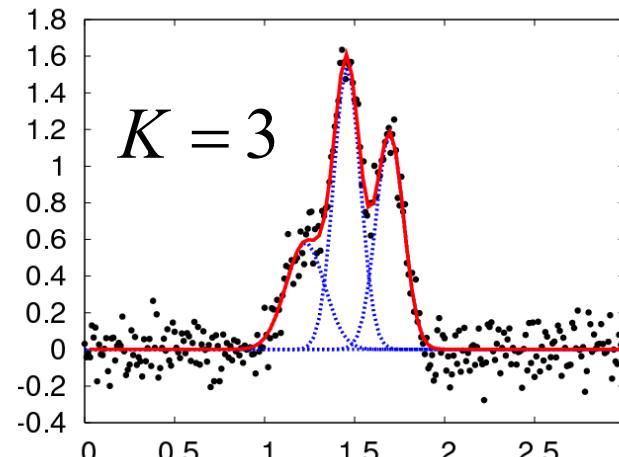
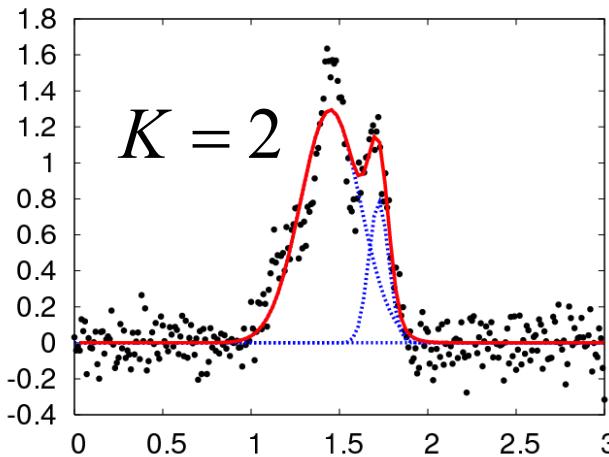
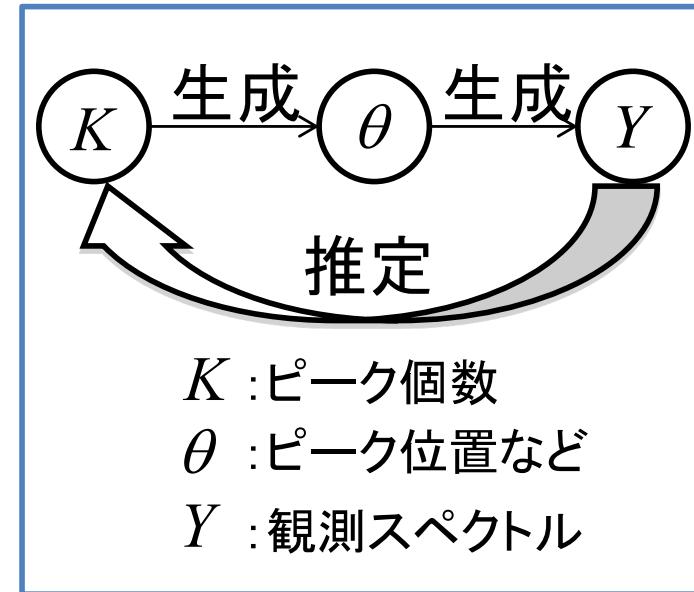
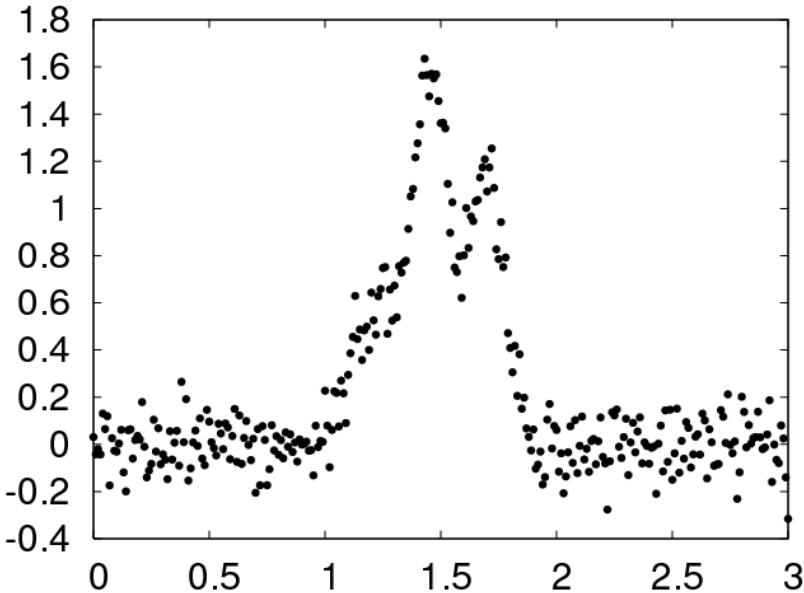


K : ピーク個数

θ : ピーク位置など

Y : 観測スペクトル

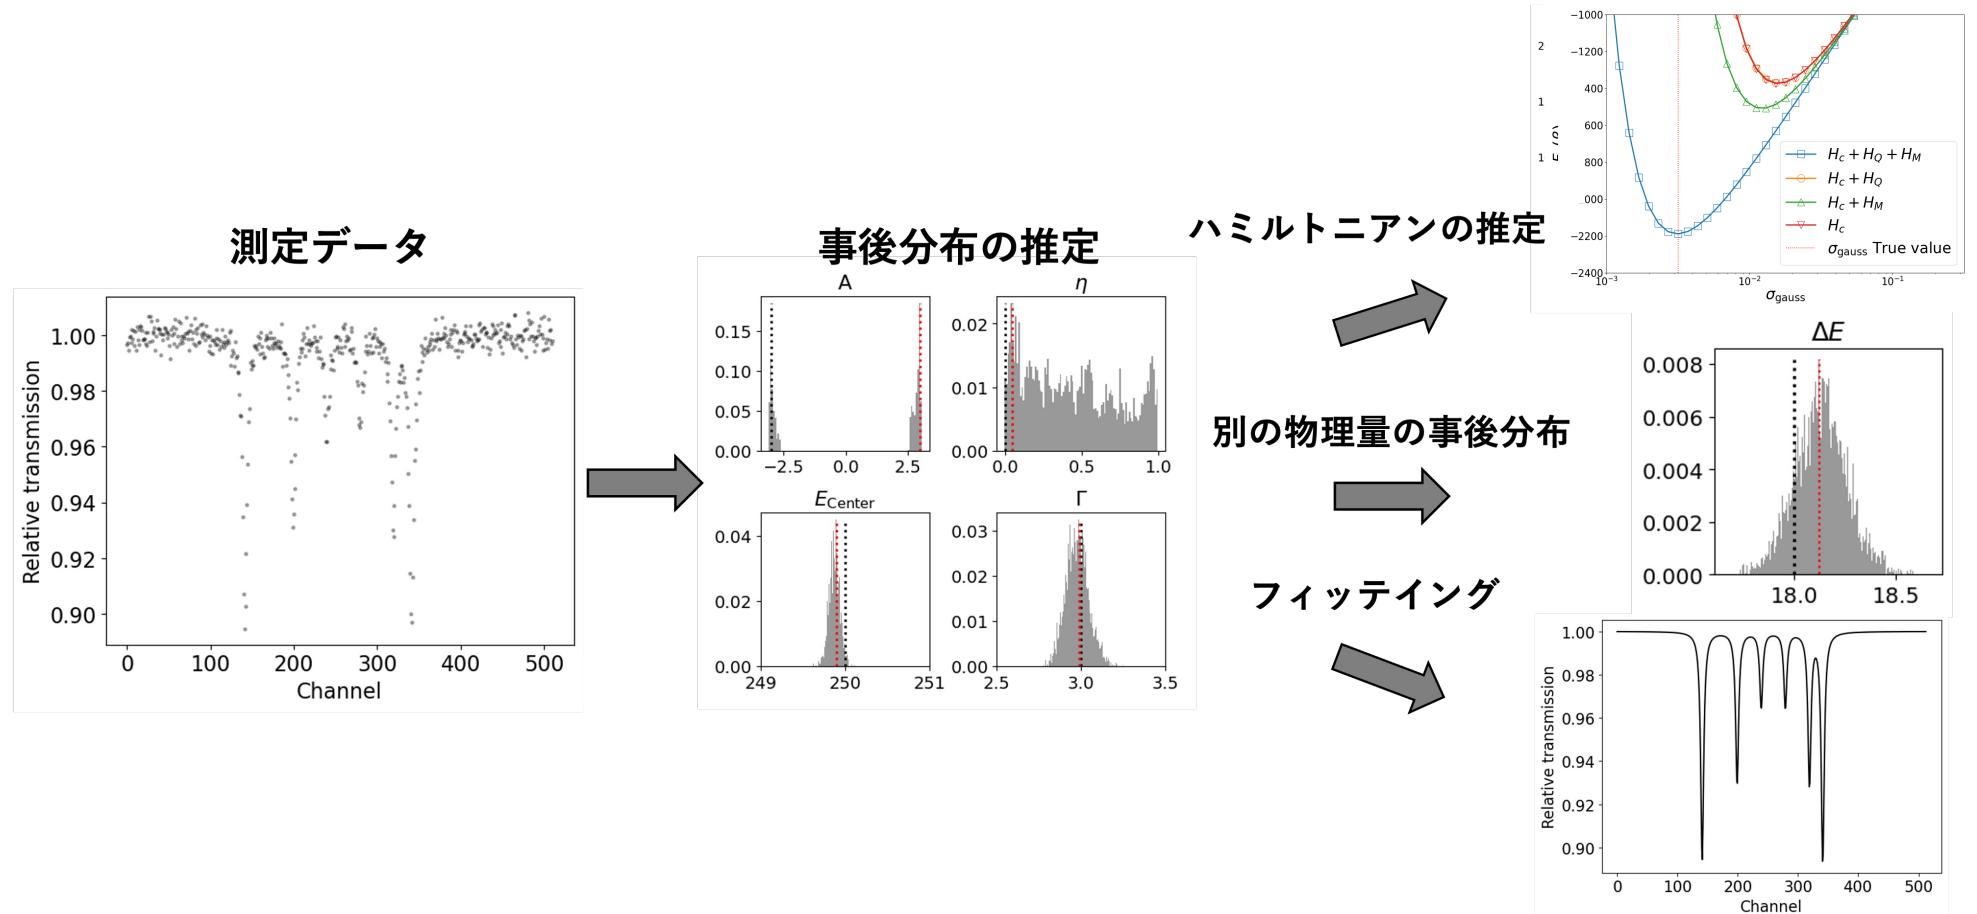
モデル選択: K をどう選ぶか



Nagata, Sugita and Okada, Bayesian spectral deconvolution with the exchange Monte Carlo method, *Neural Networks* 2012

メスバウア一分光 (1/3)

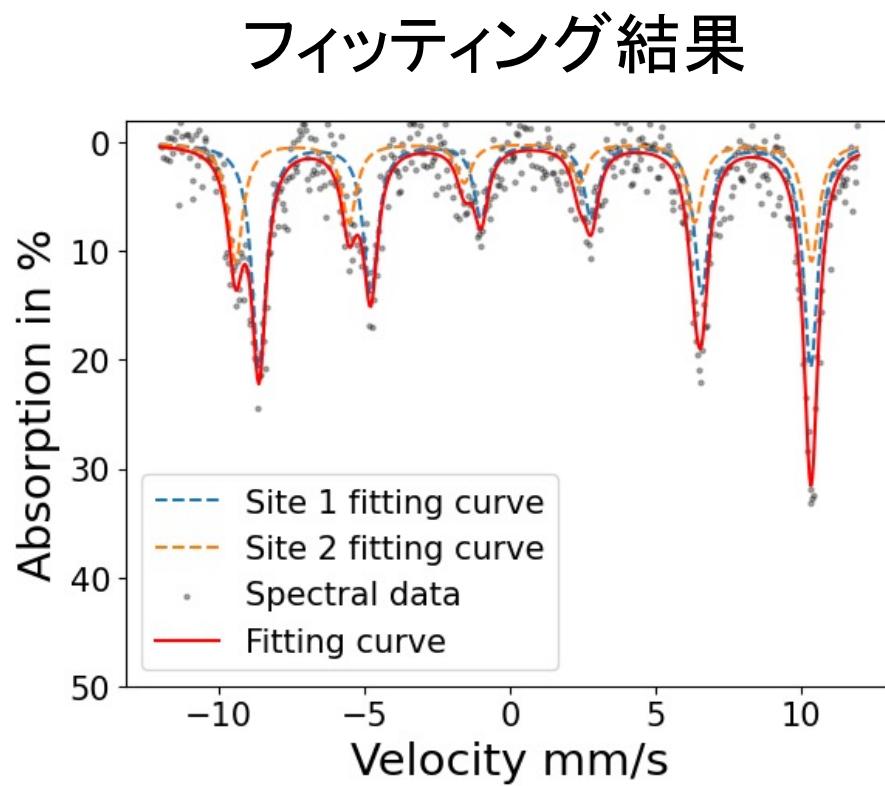
- 生成モデルがハミルトニアンで記述される例



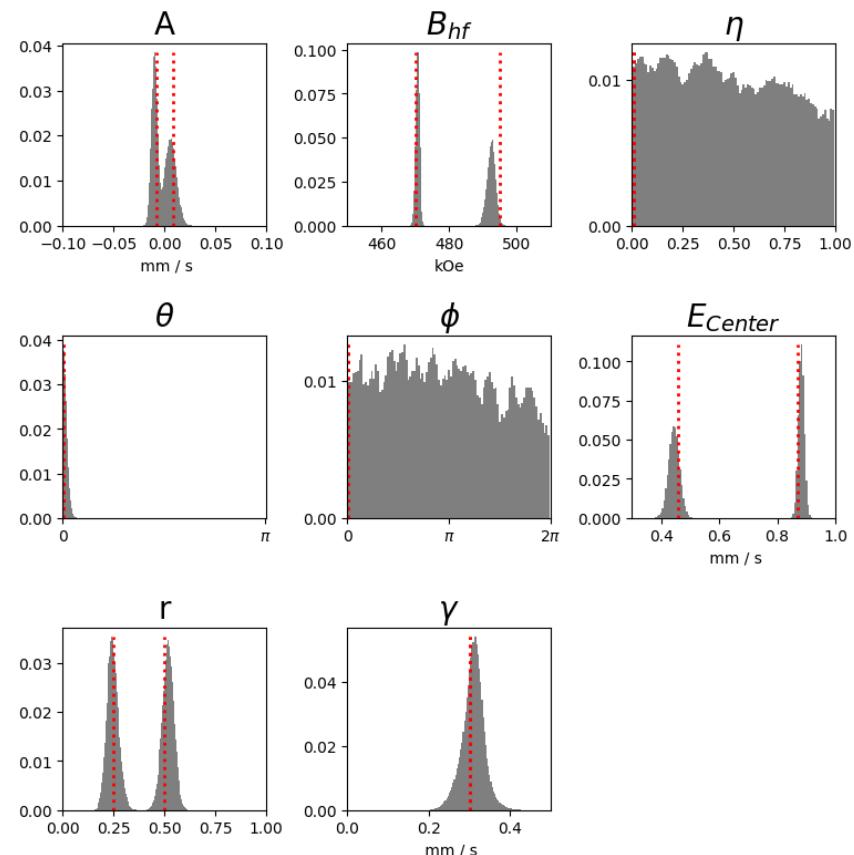
Moriguchi, Tsutsui, Katakami, Nagata, Mizumaki and Okada,
JPSJ, 91, W104002 (2022)

メスバウア一分光 (2/3)

- ・神器1: パラメータの事後分布推定

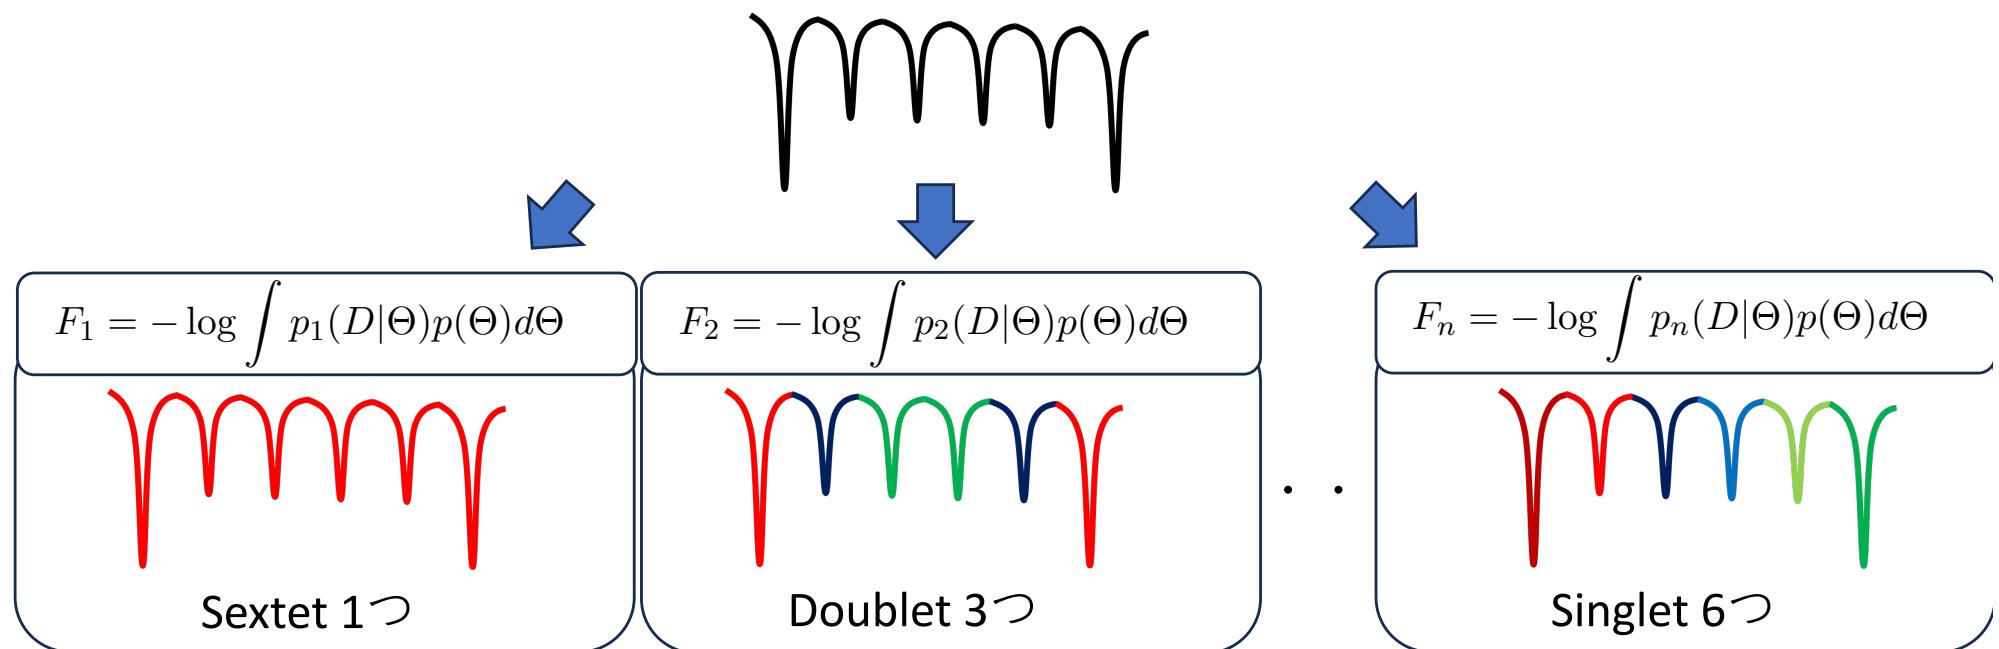


事後分布(赤い点線が実験値)



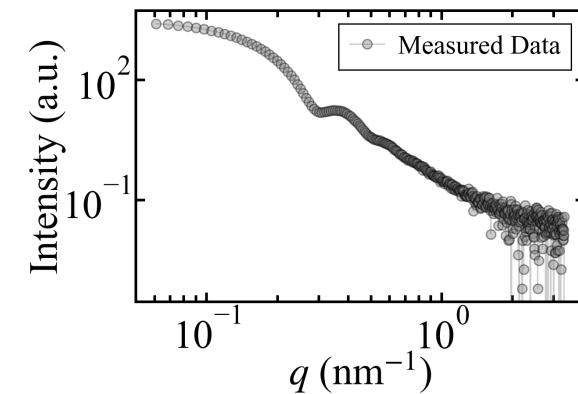
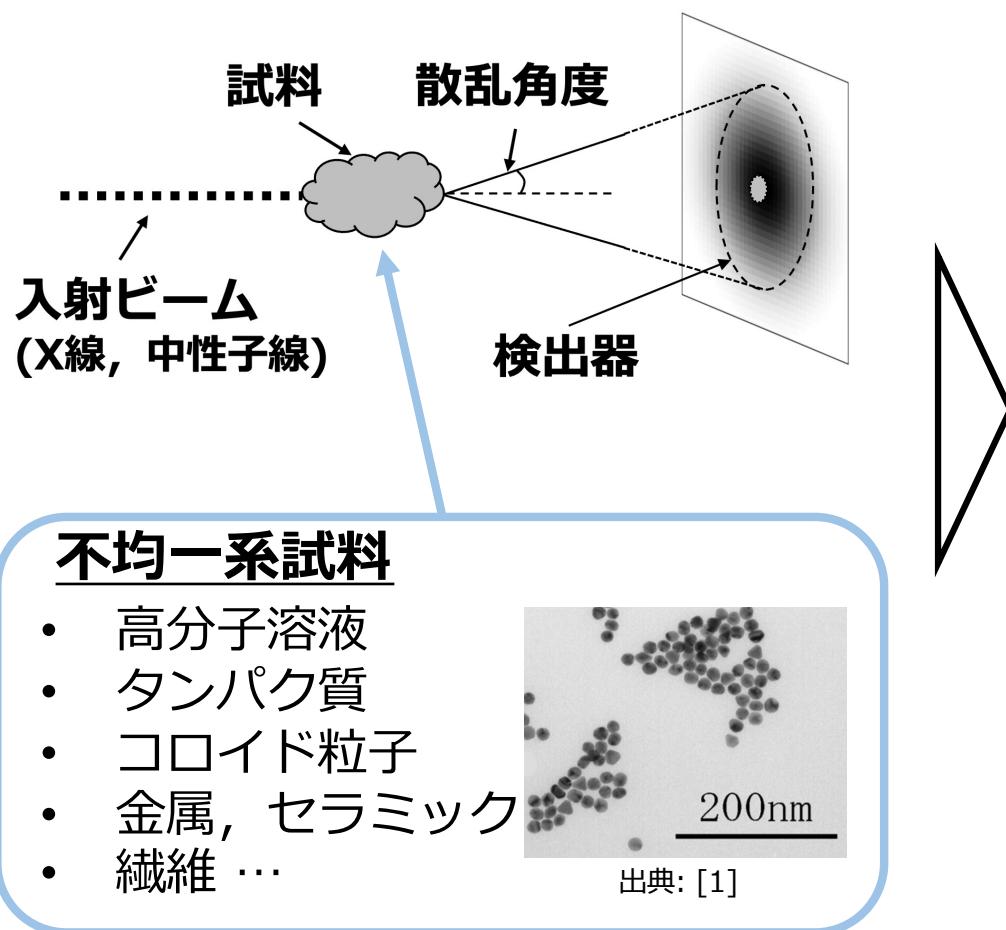
メスバウア一分光 (3/3)

- ・神器2: モデル選択: ハミルトニアン推定



最もベイズ自由エネルギーの小さいモデルを選ぶ

小角散乱 (1/5)



データ解析

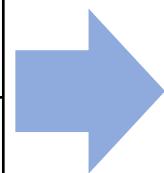
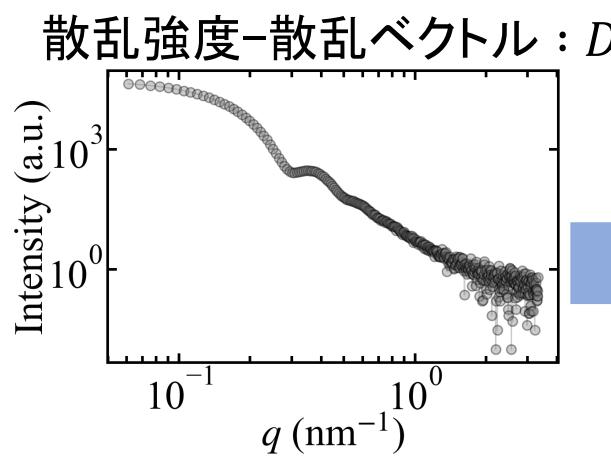
1. 散乱強度モデルを設定

$$\text{球粒子: } I(q, \Theta) = \left(\frac{\phi}{V} F(q, R_M)^2 + b \right) \times t$$

2. モデルパラメータ推定

粒径 $R_M \rightarrow 10 \text{ nm}$

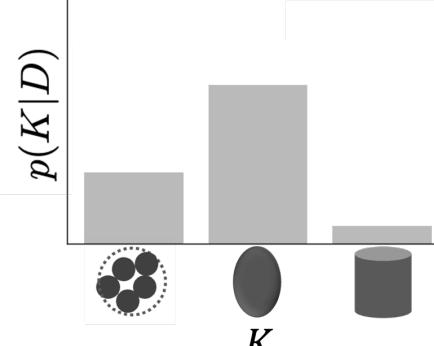
小角散乱 (2/5)



モデル選択

$$p(K|\mathcal{D}) = \frac{\int p(\mathcal{D}, \Theta, K) d\Theta}{\sum_K \int p(\mathcal{D}, \Theta, K) d\Theta}$$

試料構造を表す散乱
強度モデルの選択

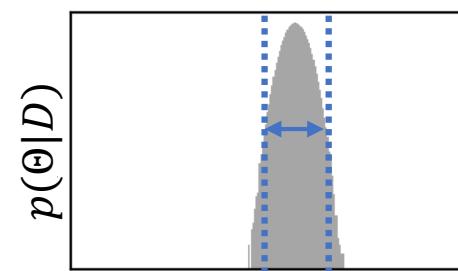


モデルの選択

パラメータ推定

$$p(\Theta|\mathcal{D}) = \frac{p(\mathcal{D}|\Theta)p(\Theta)}{\int p(\mathcal{D}, \Theta) d\Theta}$$

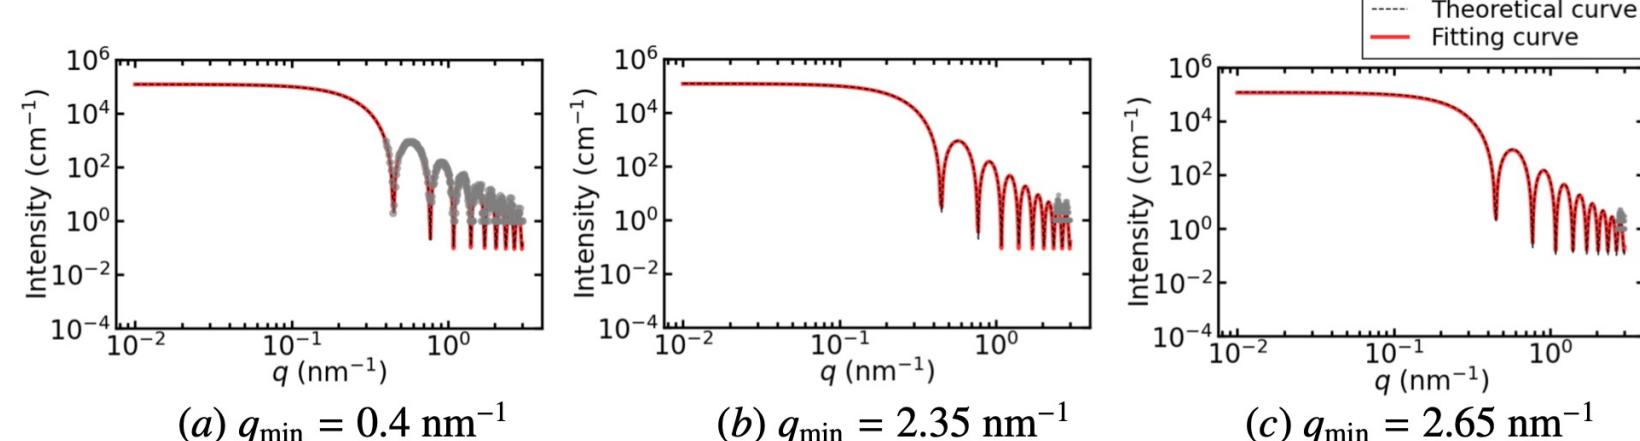
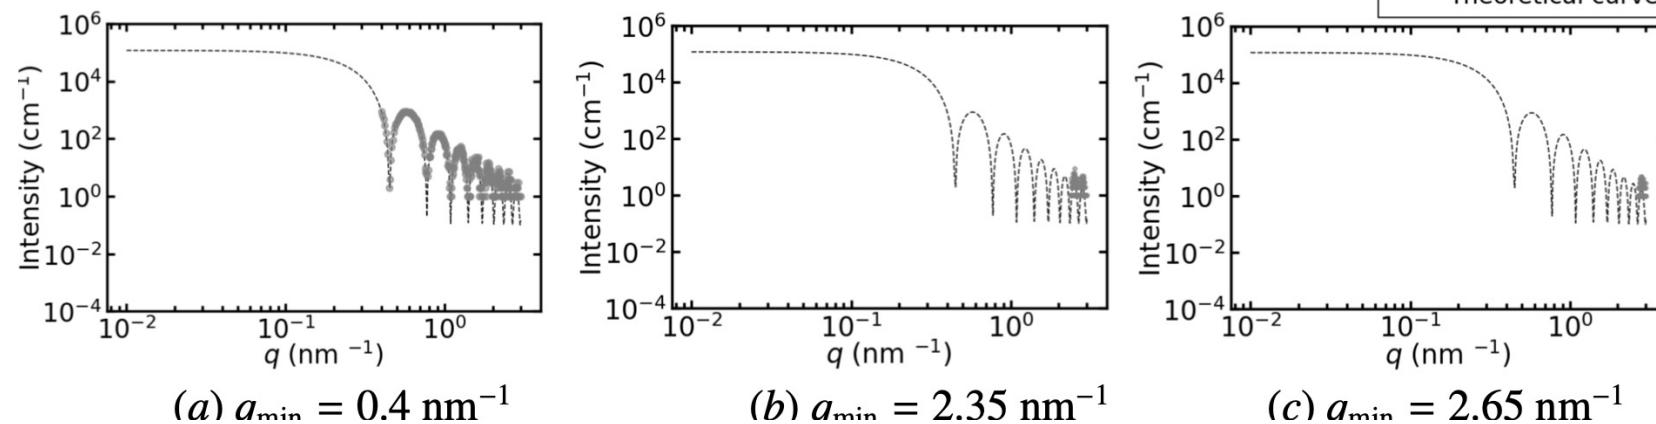
試料の大きさや密度
のパラメータを推定



信頼度の
定量評価が可能

小角散乱 (3/5)

- 小角散乱: 神器 1: 事後確率推定



Hayashi, Katakami, Kuwamoto, Nagata, Mizumaki, and Okada, *JPS J.* 92, 094002 (2023),

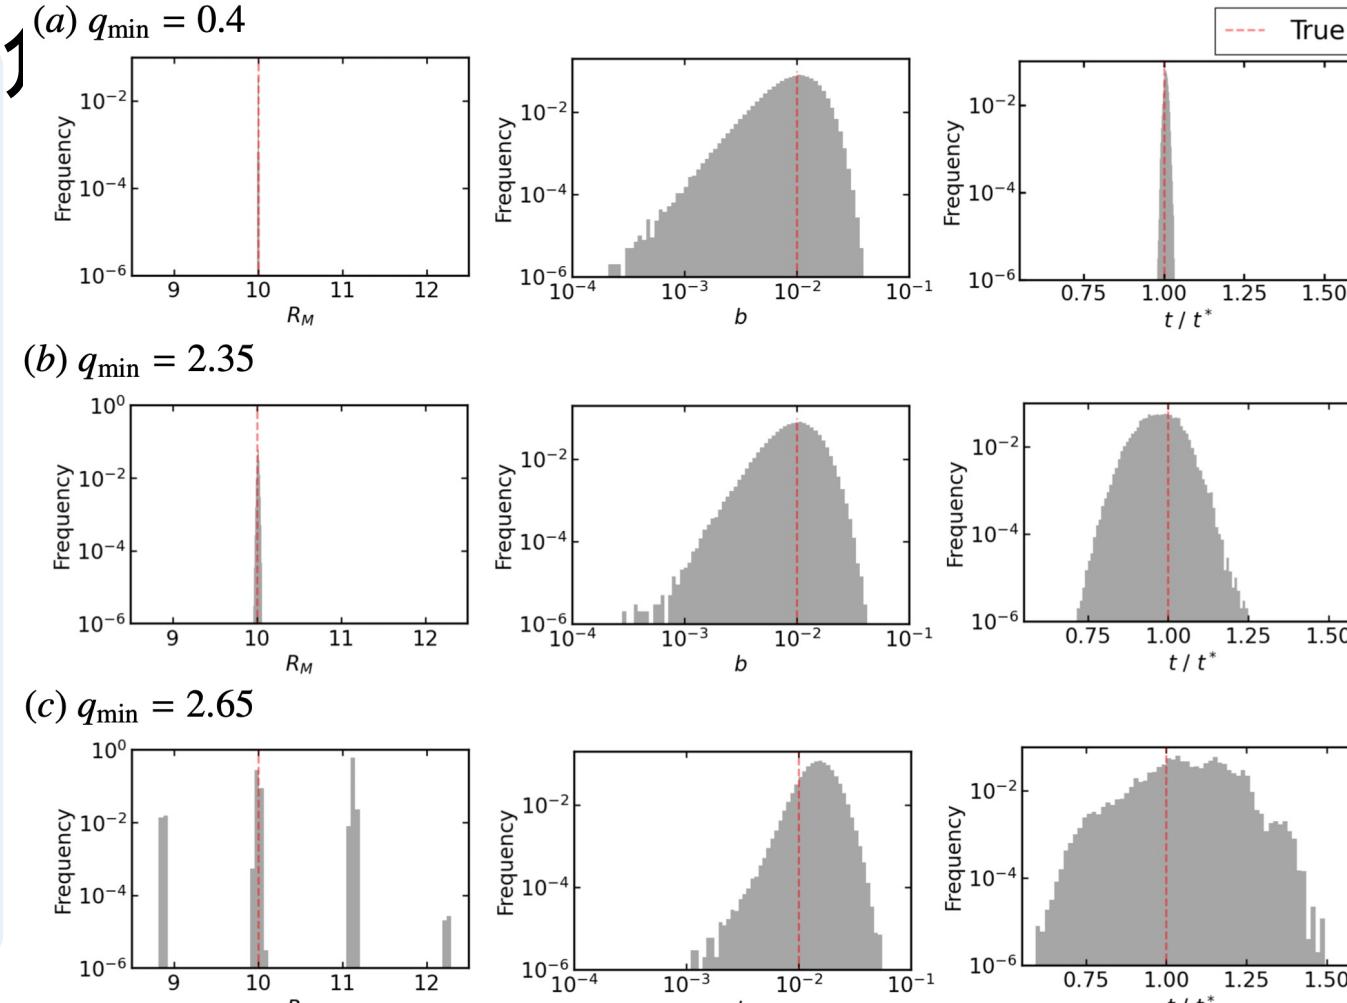
小角散乱 (4/5)

- 小角散乱: 神器 1: 事後確率推定 計測限界の導出

データ欠損

小

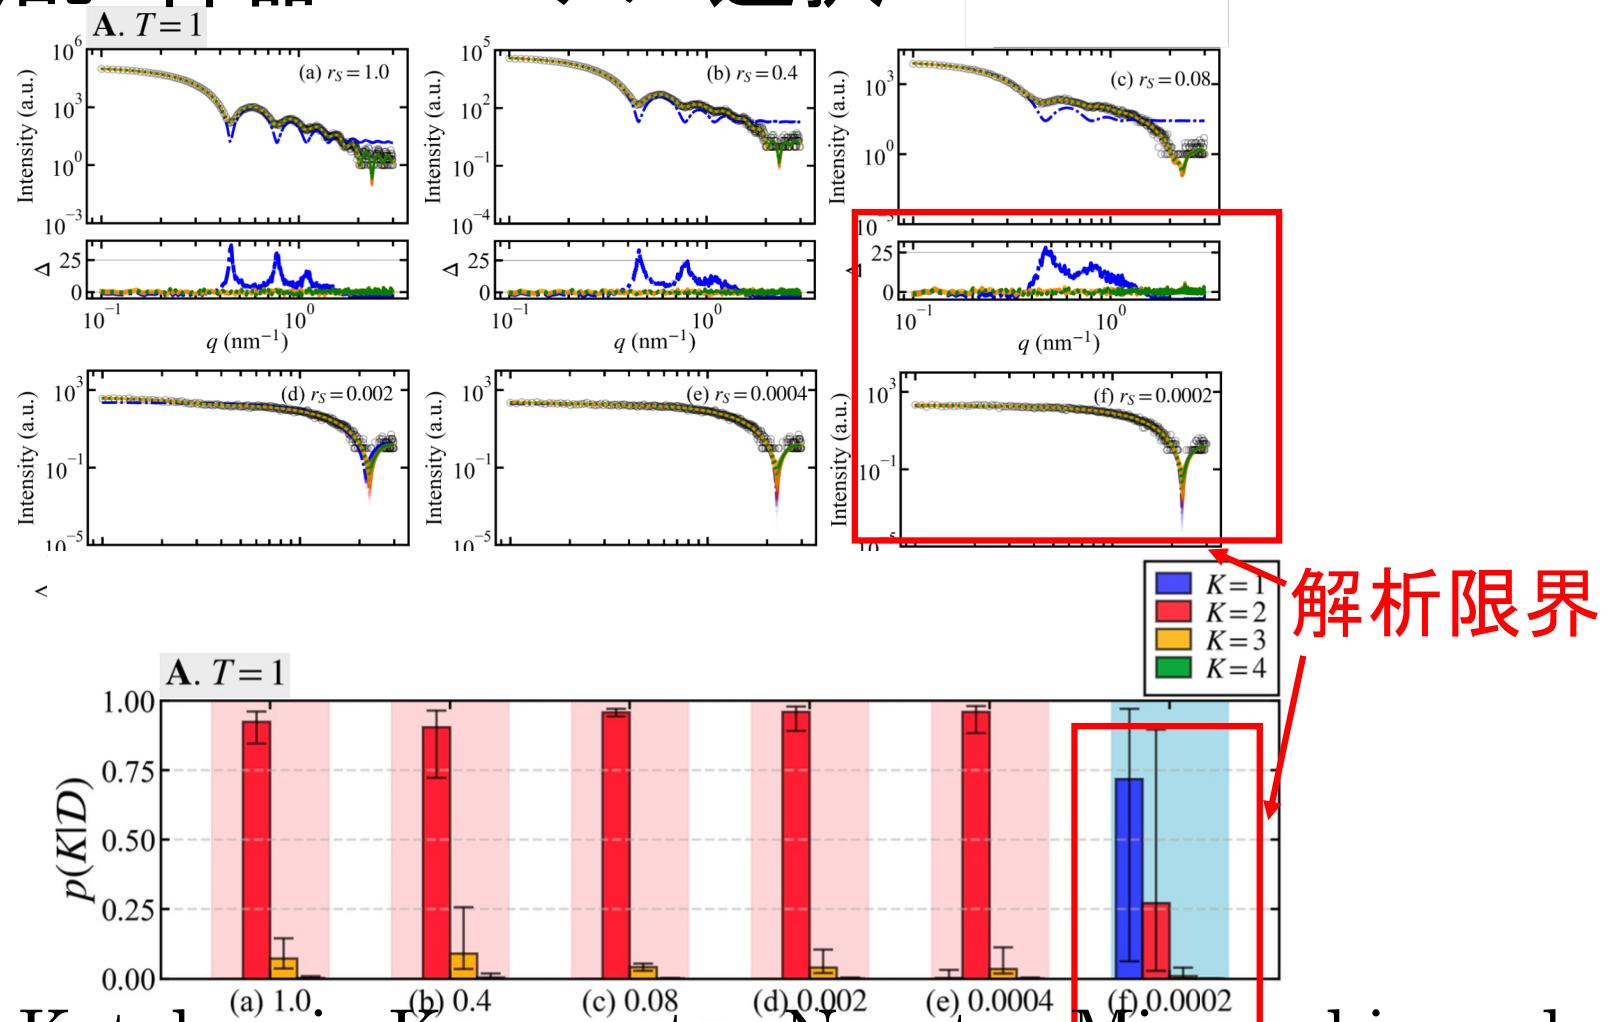
大



(c) に複数のピーク $\rightarrow q_{\min} = 2.35 - 2.65 \text{ nm}^{-1}$ で推定限界

小角散乱 (5/5)

- 小角散乱: 神器 2: モデル選択



Hayashi, Katakami, Kuwamoto, Nagata, Mizumaki, and Okada, *JPSJ* 92, 094002 (2023),

内容

- ・自己紹介
- ・階層的自然観とデータ駆動科学: ベイズ推論とスパースモデリングによる自然記述の普遍的枠組み
- ・ベイズ計測の導入
 - ・計測科学の必須条件
 - ・ベイズ計測三種の神器
 - ・ベイス計測の習得法
 - ・ $y=ax+b$ のベイズ計測の解析的取り扱い
- ・非線形系にするベイズ計測
 - ・スペクトル分解
 - ・メスバウア一分光
 - ・小角散乱
- ・ベイズ計測の啓蒙と普及の戦略
- ・まとめと今後の展開

SPring-8全ビームライン ベイズ化計画

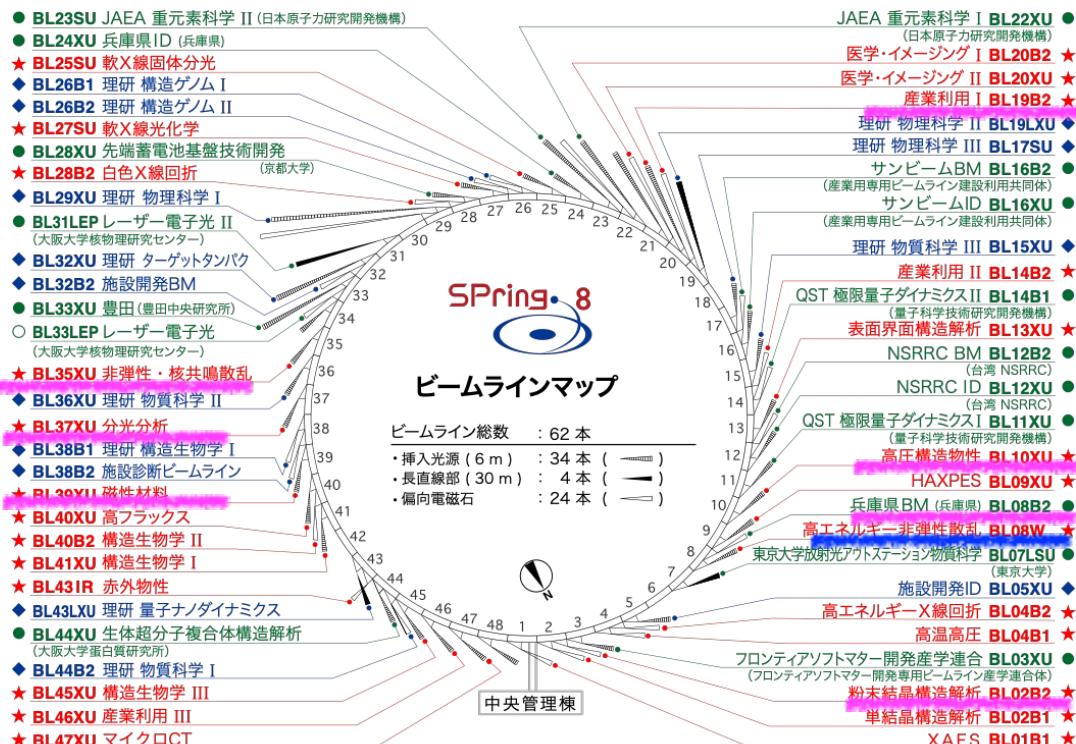
- ・ベイズ計測を啓蒙普及するのは、数理的ミニマムな研究だけでは不十分である
- ・多種多様な複雑な計測に対しても、ベイズ計測三種の神器は通用するかを実証的に調べる
- ・力強い実証方法は、SPring-8の全てのビームラインにベイズ計測を導入
- ・フラッグシップ計測施設のSPring-8を起爆点にてかベイズ計測を世界展開
- ・SPring-8全ビームラインベイズ化計画の意図である

SPring-8全ビームライン ベイズ化計画

- ・ベイズ計測を、SPring-8に導入するメリットはあるのだろうか?
- ・ベイズ計測は、日々行われているデータ解析のうち、ヒトにより恣意的に行われてきた、モデル選択とデータ統合を、パラメーターフィットと同じ枠組みで取り扱える
- ・ベイズ系をSPring-8に導入することで、これまでのデータ解析とは質的に異なるメリットを得られる

SPring-8全ビームラインベイズ化計画

敬称略



赤色BLが共用BL(JASRI担当): 計26本
全BL本数 : 62本

情報と放射光研究者のマッチング

メスバウアー

岡田研学生+筒井

小角散乱

BL08B2

BL19B2

XAS測定

BL37XU

BL39XU

岡田研学生+桑本

放射光ユーザーへの展開

時分割XRD

横山優一+河口彰吾、沙織

BL02B2

BL10XU

ユーザー : 公立大、東工大

年度	2021	2022	2023
導入	2	8	14
全BL	26	26	26

内容

- ・自己紹介
- ・階層的自然観とデータ駆動科学: ベイズ推論とスパースモデリングによる自然記述の普遍的枠組み
- ・ベイズ計測の導入
 - ・計測科学の必須条件
 - ・ベイズ計測三種の神器
 - ・ベイス計測の習得法
 - ・ $y=ax+b$ のベイズ計測の解析的取り扱い
- ・非線形系にするベイズ計測
 - ・スペクトル分解
 - ・メスバウア一分光
 - ・小角散乱
- ・ベイズ計測の啓蒙と普及の戦略
- ・まとめと今後の展開

まとめと今後の展望

- $y=ax+b$ を例にベイズ計測とベイズ計測三種の神器を解説。一般的な非線形の計測に導入可能
- ベイズ計測の物性物理学への導入が大きなビジネスチャンス。ベイズ計測の導入による計測科学のゲームチェンジング
- ベイズ計測の普及戦略としてのSPring-8全ビームラインベイズ化計画
- 物理学全般を取り扱うことができるデータ駆動科学の枠組みの紹介
- 物理学科/各学科にデータ駆動科学ー講座導入
- 民間企業のR&D組織の新陳代謝を加速

物理学科/各学科に データ駆動科学—講座導入

理論物理

実験物理

素粒子論

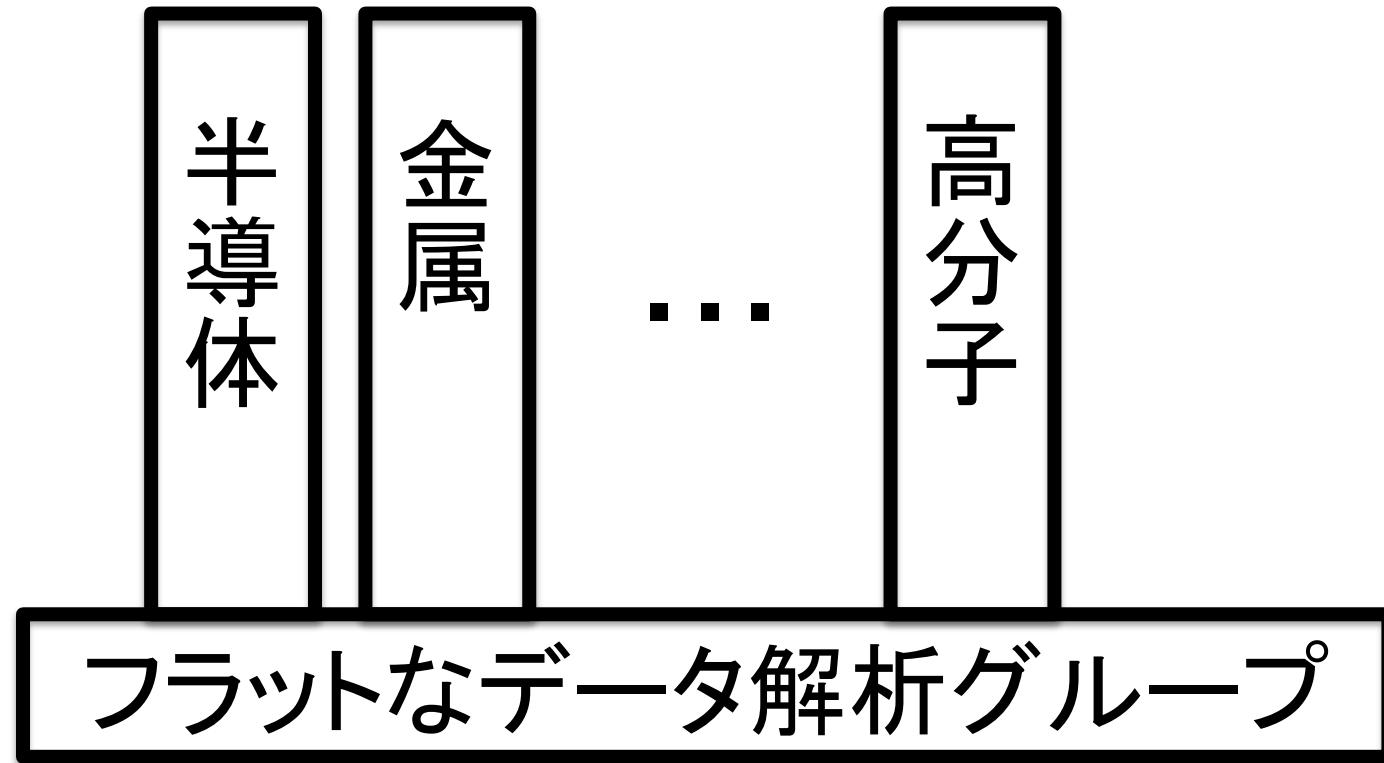
物性理論

光物性

磁性物理

データ駆動科学講座

データ駆動科学による R&D組織のフラット化と人材の流動化



ある縦組織がリストラされても、フラットなデータ解析グループに沿って、他の縦組織にソフトランディングでき、人材の流動化が加速される。